



Trabajo Final de Graduación

Optimización de la Experiencia del Cliente en Aerolíneas: Insights desde Skytrax y Twitter

Universidad del CEMA
Lic. Analítica de Negocios
Magdalena Minoletti
44.417.144

Tutor: Paula Mariela Iaccarino
Analítica de Negocios Avanzada 2024

Resumen

La industria aérea enfrenta un entorno competitivo donde la percepción de los pasajeros impacta significativamente en su éxito. Este trabajo se centra en United Airlines y su competencia, analizando las reseñas y puntuaciones de Skytrax y datos no estructurados de Twitter mediante técnicas de Análisis de Sentimientos y Modelos de Clasificación. El objetivo es identificar áreas de mejora para optimizar la experiencia del cliente y fortalecer la competitividad de la aerolínea.

Los resultados proponen estrategias para incrementar la satisfacción del cliente, abordar problemas recurrentes y diferenciar a United Airlines en el mercado. La implementación de esta metodología permitirá aprovechar datos públicos para identificar tendencias, priorizar acciones y mejorar la fidelización de los pasajeros, mejorando las puntuaciones actuales y posicionando a la aerolínea como líder en experiencia del cliente.

Índice

Resumen	1
Índice	2
Introducción	3
1.1 El problema de la percepción y competitividad en la industria aérea	3
1.2 Data Product	4
1.3 Desarrollo del Data Product	5
Marco Teórico	11
2.1 Procesamiento de Lenguaje Natural (NLP)	11
2.2 Aprendizaje supervisado	16
2.3 Aprendizaje no supervisado	18
Desarrollo	20
3.1 Metodología	20
3.2 Recolección de datos	21
3.3 Limpieza y transformación de datos	23
3.4 Análisis exploratorio de datos	29
3.5 Desarrollo de modelos y resultados	34
3.5.1 Análisis de sentimientos y tópicos de temas de Skytrax	34
3.5.2 Modelos de clasificación de Recomendación	42
3.5.3 Análisis de sentimientos en Twitter	48
3.6 Insights y acciones recomendadas	56
3.6.1 Análisis de sentimientos y tópicos de Skytrax	57
3.6.2 Modelos de Clasificación de Recomendación	58
3.6.3 Análisis de sentimientos en Twitter	59
3.7 Futuras Mejoras	59
Conclusiones generales	61
Referencias	63
Anexos	66

Introducción

1.1 El problema de la percepción y competitividad en la industria aérea

La industria aérea se enfrenta a un entorno competitivo y desafiante, donde la percepción de los pasajeros juega un papel crucial en la reputación y el éxito de las aerolíneas. En general, todas las compañías aéreas deben lidiar con el aumento de las expectativas de los clientes teniendo en cuenta la influencia de las redes sociales y plataformas de reseñas online. Estas opiniones tienen un alcance significativo y pueden impactar directamente en la toma de decisiones de los consumidores.

Actualmente, las redes sociales y las plataformas de reseñas online tienen un rol fundamental. Funcionan como el espacio donde los clientes expresan su satisfacción o frustración, y esas opiniones tienen un alcance grande. Hace unos años atrás, las opiniones provienen de personas cercanas y se confiaba en su opinión para comprar o no un producto o un servicio. Hoy en día, la situación es muy distinta. Además de las personas cercanas, también se confía en la opinión de personas desconocidas. Según los datos de la Local Consumer Review Survey de 2016 , las opiniones en estas plataformas impacta directamente en la decisión de compra: el 84% de los clientes confía en las reseñas online tanto como en una recomendación personal [1]. En el caso de United Airlines, la compañía aérea elegida para este trabajo, es especialmente preocupante. Entre 2012 y 2018, el puntaje promedio de satisfacción del cliente fue de 4,65 [2] cuando en promedio general de la competencia era de 5,65 [2]. Aunque, según Airline Quality (Skytrax), actualmente, el promedio es de 3 sobre 10 [3]. Estos datos demuestran la brecha entre las expectativas de los pasajeros y la experiencia real que están recibiendo.

Estas percepciones negativas no solo impactan a United, sino que también afectan de manera similar a la competencia, generando puntajes bajos en toda la industria. Hay una desconexión clara entre lo que las aerolíneas prometen y lo que los clientes realmente experimentan. Además, una comunicación ineficiente y la falta de confianza en los servicios ofrecidos dificultan retener clientes y atraer nuevos.

Este proyecto integra conceptos de la carrera Analítica de negocios, como la transformación de datos estructurados y no estructurados en información relevante para tomar decisiones

estratégicas. El análisis de reseñas y de tweets mediante técnicas de procesamiento de lenguaje natural (NLP) permite identificar patrones en la percepción de los pasajeros, evaluar puntos fuertes y áreas de mejora en la experiencia de usuario. Al comparar los datos de United Airlines con los de sus competidores, el objetivo final es identificar qué aspectos se deben mejorar para elevar la experiencia del cliente y, en consecuencia, fortalecer la posición competitiva de la aerolínea en el mercado.

1.2 Data Product

Considerando el problema a resolver, es fundamental llevar a cabo un análisis exhaustivo de la solución basada en datos que se quiera implementar. Por ello, para este trabajo se utilizará un framework conocido como Data Product Canvas (Anexo 1). Esta herramienta facilita una visión integral del proyecto, permitiendo analizar y definir diez componentes clave:

1. Problema: Definición del problema, identificación de actores afectados y cuantificación del impacto que dicho problema conlleva.
2. Solución: Explicación de la solución, detallando uso de herramientas de datos y output esperado.
3. Datos: Definición de datos requeridos, aclaración del nivel de acceso o disponibilidad a dichos datos e identificación de las fuentes a utilizar.
4. Hipótesis: Explicación de la afirmación que se pretende demostrar y los resultados anticipados que se esperan obtener.
5. Actores: Definición de clientes, usuarios y stakeholders
6. Acciones: Descripción de las acciones estratégicas a desarrollarse
7. KPI's / Métricas: Identificación de métricas claves para evaluar la solución
8. Valores: Cuantificación del problema, análisis de la solución base actual y proyección de los beneficios esperados.
9. Riesgos: Identificación y mapeo de potenciales riesgos
10. Performance / Impacto: Análisis del impacto previsto del producto

1.3 Desarrollo del Data Product

En esta sección se describirán los aspectos claves que deben considerarse para el desarrollo del producto de datos:

Problema:

United Airlines enfrenta el desafío de comprender y gestionar de manera estructurada la percepción de sus pasajeros para optimizar su experiencia y tener ventajas competitivas. Actualmente, las opiniones y comentarios sobre la aerolínea se encuentran dispersas en plataformas de reseñas y Twitter, lo que podría dificultar la identificación de las necesidades y expectativas de los clientes, la priorización de mejoras y la comprensión de los motivos detrás de su bajo puntaje general. Además, la aerolínea podría beneficiarse de un análisis comparativo sistemático con la competencia, lo que permitiría identificar sus fortalezas y áreas de mejora. Al aprovechar mejor las fuentes de información, especialmente de los datos no estructurados como los de Twitter, United Airlines podría detectar tendencias emergentes y responder de manera proactivo. Esto podría marcar la diferencia en la retención de clientes en un mercado cada vez más competitivo.

Solución:

Implementar un sistema de análisis avanzado compuesto por múltiples soluciones complementarias que permita mejorar la experiencia del cliente y aumentar la competitividad de las aerolíneas.

Para ello, se llevarán a cabo:

- *Análisis de Sentimientos y Tópicos de las reseñas de Skytrax* para identificar las razones de las emociones.
- *Modelos de Clasificación que determinen si el pasajero recomendaría o no el servicio*, ayudando a entender los factores que influyen en la satisfacción.
- *Análisis de Sentimientos en Twitter*, permitiendo evaluar la percepción del público en tiempo real.

El objetivo final es implementar mejoras que incrementen las calificaciones de los pasajeros y posicionen a United Airlines como líder en su mercado. Además, Este enfoque generará insights que faciliten el diseño de estrategias de comunicación, optimización de la experiencia de los clientes, y gestión de crisis, permitiendo a la aerolínea responder de manera efectiva a las expectativas de los pasajeros.

Datos:

Para el desarrollo de este proyecto se utilizarán dos fuentes principales de información: Skytrax y Twitter, que permitirán realizar un análisis integral y comparativo de la experiencia del cliente.

Skytrax proporciona una base estructurada de reseñas y puntuaciones de aerolíneas (Anexo 2), donde se seleccionarán las opiniones y calificaciones de United Airlines junto con las de sus principales competidores nacionales, como Delta, American Airlines y Southwest. Esta fuente ofrece información detallada que incluye las opiniones y puntuaciones de los vuelos [2], aspectos específicos relacionados con la experiencia del pasajero, y variables adicionales que describen los servicios ofrecidos durante el vuelo, como la comodidad del asiento, el entretenimiento a bordo y el trato de la tripulación. Además, para enriquecer el análisis, los datos de Skytrax serán unificados con información de aeropuertos [4] mediante el uso del código IATA, lo que permitirá incorporar detalles relevantes sobre las ubicaciones de origen y destino de los vuelos.

Por otro lado, **Twitter** aporta información no estructurada a partir de opiniones y comentarios espontáneos que los usuarios publican mencionando a las aerolíneas estadounidenses, incluida United Airlines (Anexo 3). Estos datos permitirán capturar percepciones genuinas de los pasajeros, tomando en cuenta variables clave como la fecha y hora de publicación del tweet, así como el contenido de los comentarios, haciendo especial énfasis en los motivos de las reseñas negativas [5].

Ambas fuentes, Skytrax y Twitter, representan información pública y accesible, lo que permite aprovecharlas de manera complementaria para obtener una visión integral de la percepción de los pasajeros. Mientras Skytrax ofrece un análisis estructurado y detallado de las experiencias de vuelo, Twitter aporta dinamismo y actualidad, facilitando la detección de problemas y necesidades en tiempo real. La combinación de estos datos posibilitará un análisis comparativo

con la competencia, la identificación de áreas de mejora y la implementación de estrategias orientadas a optimizar la experiencia del cliente y fortalecer la posición de United Airlines en el mercado.

Hipótesis:

Se considera que la implementación de un sistema de análisis de opiniones y reseñas permitirá incrementar la satisfacción de los clientes, reflejada en un mayor nivel de recomendación del servicio. Además, facilitará la identificación de patrones de insatisfacción para abordarlos de manera eficaz, optimizando así los recursos operativos de la aerolínea. Por último, se espera lograr un mayor conocimiento de las necesidades y preferencias de los clientes, lo que contribuirá a mejorar la experiencia general y la competitividad de United Airlines. Por ejemplo, si se detecta un sentimiento generalizado de frustración en las reseñas debido a retrasos frecuentes en los vuelos, la aerolínea podrá implementar medidas específicas, como mejoras en la comunicación con los pasajeros o ajustes en la planificación operativa, reforzando así la percepción de compromiso y atención a sus clientes.

Actores:

Este proyecto está enfocado en distintos sectores de la empresa:

- **Marketing:** encargado de identificar tendencias y ajustar las estrategias promocionales en función de los insights obtenidos.
- **Operaciones:** cuya responsabilidad será priorizar mejoras en los procesos críticos con base en los hallazgos del análisis.
- **Atención al Cliente:** enfocado en identificar patrones recurrentes en las quejas de los pasajeros para optimizar las respuestas y resolver problemas de manera más efectiva.

Acciones

Luego de implementar este Data Product, las acciones que deben seguir son las acciones:

- Establecer alertas automáticas para identificar problemas recurrentes en las opiniones de los pasajeros.

- Realizar una clasificación de comentarios con base en su contenido y nivel de impacto.
- Implementar un protocolo de respuestas a opiniones negativas para abordar eficazmente las quejas de los clientes.
- Brindar entrenamiento al personal para optimizar la gestión de la retroalimentación y mejorar la atención al cliente.

KPIs

El análisis de los datos y la evaluación del rendimiento de los modelos requieren indicadores clave de desempeño (KPIs) que permiten medir tanto la calidad de las predicciones como el impacto general de los modelos. A continuación, se describen los KPIs técnicos y del negocio para cada uno de las bases de datos:

KPIs para el Modelo de análisis de sentimientos con la Base de Skytrax

- **KPIs Técnico:**
 - *Velocidad de Procesamiento:* Tiempo promedio que tarda el modelo en analizar y clasificar un conjunto de reseñas. Es clave para evaluar su eficiencia en entornos con grandes volúmenes de datos.
- **KPIs de negocio:**
 - *Distribución de Sentimientos:* Mide la proporción de comentarios clasificados en cada categoría de sentimiento (positivo, negativo, neutral). Se calcula de manera similar al modelo de Twitter, donde se determina el porcentaje de cada tipo de sentimiento en relación con el total de comentarios.
 - *Variación en los Tópicos:* Mide los cambios en los temas y opiniones a lo largo del tiempo o entre diferentes conjuntos de datos (por ejemplo, entre distintas aerolíneas o entre reseñas de distintos años). Permite identificar tendencias emergentes o temas recurrentes.

KPIs para el Modelos de clasificación con la Base de Skytrax

- **KPIs Técnicos:**
 - *Precisión (Accuracy):* Determina cuántas clasificaciones de sentimientos fueron correctas en relación con el total de predicciones.

- *Recall*: Asegura que los sentimientos negativos sean identificados correctamente, ayudando a capturar todos los comentarios relevantes en esa categoría.
- **KPIs de negocio:**
 - *Nivel de Recomendación*: Mide la disposición de los pasajeros para recomendar la aerolínea a otros, basándose en el análisis de sentimientos y las características de las reseñas. Se evalúa mediante los comentarios donde los usuarios indican explícitamente si recomendarían o no el servicio.

KPIs para el Modelo con la Base de Twitter

- **KPIs Técnicos:**
 - *Precisión del modelo (Accuracy)*: Determina cuántas clasificaciones de sentimientos fueron correctas en relación con el total de predicciones en el análisis de sentimientos de los tweets.
 - *AUC (Área bajo la Curva ROC)*: Evalúa la capacidad del modelo de clasificación binaria de sentimientos (positivo/negativo), indicando cuán bien identifica entre ambas categorías. Un valor alto indica una mejor capacidad del modelo para separar correctamente las categorías.
- **KPIs de negocio:**
 - *Distribución de Sentimientos*: Similar al modelo de Skytrax, mide la proporción de comentarios clasificados en cada una de las categorías de sentimientos (positivo, negativo, neutral)
 - *Tendencia de Sentimientos en el Tiempo*: Analiza cómo varían los sentimientos a lo largo del tiempo, permitiendo identificar picos de insatisfacción o satisfacción en períodos específicos. Este análisis se realiza agregando las clasificaciones de sentimientos por intervalos de tiempo (por ejemplo, día, semana o mes).

En resumen, los KPIs tienen dos funciones clave: el primero, controlar la eficiencia del sistema, asegurando que el modelo funcione correctamente, optimizando su capacidad para clasificar los sentimientos de manera precisa y eficaz y por último, controlar el impacto en el negocio y, permitiendo identificar rápidamente variaciones en los sentimientos, como un aumento de comentarios negativos que podría reflejar una disminución en la satisfacción del cliente.

Impacto

La implementación de estas acciones permitirá alcanzar los siguientes resultados:

- **Mejora en la satisfacción del cliente** mediante una atención más eficiente y personalizada.
- **Optimización de recursos**, al identificar áreas críticas y priorizar acciones.
- **Incremento en la fidelización** de los pasajeros al resolver problemas de manera proactiva.
- **Diferenciación competitiva** frente a otras aerolíneas, posicionando a United Airlines como líder en experiencia del cliente.

Riesgos

Durante la implementación del proyecto, se deben considerar los siguientes riesgos:

- Antigüedad de los datos, que podría limitar la relevancia de los insights obtenidos.
- Sesgo en las reseñas, debido a que los pasajeros suelen expresar opiniones extremas.
- Dificultades en la toma de datos, especialmente al manejar información no estructurada y dispersa.

Marco Teórico

El marco teórico de este trabajo tiene como objetivo establecer las bases conceptuales y teóricas necesarias para comprender el análisis de sentimientos aplicado a las aerolíneas. En la actualidad, las redes sociales y páginas de reseñas representan canales claves para que los usuarios expresen opiniones y experiencias sobre los servicios que reciben. Este flujo masivo de información representa una oportunidad invaluable para las empresas, ya que permite identificar patrones, tendencias y áreas de mejora sin necesidad de recurrir a métodos más tradicionales y laboriosos, como las encuestas posteriores al vuelo.

En este contexto, el análisis de sentimientos surge como una herramienta poderosa dentro del procesamiento de lenguaje natural (PLN), capaz de categorizar las opiniones de los usuarios en diferentes niveles de percepción (positiva, neutral o negativa). La combinación de modelos de aprendizaje automático y arquitecturas avanzadas, como los Large Language Models (LLMs), permite abordar estos desafíos con un alto grado de precisión.

2.1 Procesamiento de Lenguaje Natural (NLP)

Conceptos básicos de análisis de sentimientos

La Inteligencia Artificial (IA) se define como el campo de la informática que busca desarrollar sistemas capaces de realizar tareas que requieren inteligencia humana, como el reconocimiento de patrones, la toma de decisiones y el procesamiento de datos complejos [6]. Dentro de este campo, el procesamiento de lenguaje natural (PLN) es una subdisciplina que se enfoca en la interacción entre las computadoras y el lenguaje humano, permitiendo a las máquinas entender, interpretar y generar texto [7].

El PLN permite analizar grandes volúmenes de texto y extraer insights útiles, como identificar las emociones o intenciones detrás de las opiniones expresadas en redes sociales. Este enfoque es particularmente relevante en sectores como el de las aerolíneas, donde las opiniones de los clientes en plataformas públicas son un recurso valioso para comprender su satisfacción y mejorar los servicios ofrecidos. Por ejemplo, al analizar comentarios como "el vuelo llegó tarde

y la comida fue mala", el PLN puede identificar que el sentimiento es negativo y que las áreas de mejora incluyen puntualidad y calidad de alimentos.

El análisis de sentimientos, también conocido como minería de opiniones, es el proceso de identificar y clasificar emociones o actitudes expresadas en un texto. Se utiliza comúnmente para determinar si el sentimiento detrás de una opinión es positivo, negativo o neutral. Esta técnica es una parte esencial del procesamiento de lenguaje natural y tiene aplicaciones significativas en la industria, como la evaluación de productos y el análisis de comentarios de clientes [7].

En la industria aérea, el análisis de sentimientos juega un papel crucial al permitir a las aerolíneas identificar las preocupaciones más comunes de los clientes, evaluar su satisfacción y responder de manera proactiva a sus necesidades. En el estudio de Medhat, Hassan y Korashy se ha demostrado que este enfoque puede ayudar a predecir comportamientos futuros de los clientes y mejorar la experiencia del usuario [8].

El proceso del análisis de sentimientos, como se observa en la Figura 1, puede dividirse en varias etapas fundamentales que permiten convertir el texto en información útil y cuantificable [8]:




Figura 1: Proceso de análisis de sentimientos en reseñas de productos. Imagen extraída de [10].

1. **Reseñas de productos:** El proceso inicia con la recopilación de textos u opiniones generadas por los usuarios, como comentarios, publicaciones en redes sociales o reseñas de productos y servicios.

2. **Identificación de sentimientos:** En esta etapa se identifican palabras o frases con carga subjetiva, conocidas como términos de opinión. Estos términos son indicadores clave que permiten detectar la intención o actitud del usuario en el texto.
3. **Selección de características:** Se extraen las características relevantes del texto, que pueden incluir palabras clave, puntuaciones, o atributos gramaticales. Estas características son transformadas en una representación cuantificable que los modelos de aprendizaje automático pueden utilizar para su entrenamiento.
4. **Clasificación de sentimientos:** Utilizando las características seleccionadas, se aplican algoritmos de clasificación como Naive Bayes, Support Vector Machines (SVM), o métodos más avanzados como las redes neuronales. El objetivo es asignar una etiqueta al texto que indique su polaridad: positiva, negativa o neutral.
5. **Polaridad del sentimiento:** Finalmente, el resultado del análisis es la polaridad del **sentimiento**, que resume la clasificación realizada en las etapas previas. Este resultado permite interpretar la percepción general de los usuarios respecto al objeto de estudio.

De acuerdo con Medhat, Hassan y Korashy [8], este flujo estructurado facilita el procesamiento eficiente de grandes volúmenes de texto, permitiendo obtener insights útiles para la toma de decisiones en diversas industrias. En el contexto de este trabajo, estos pasos permiten procesar reseñas de pasajeros para identificar qué factores específicos, como por ejemplo, la comida, la puntualidad o la atención, generan las mayores percepciones negativas o positivas, guiando a las aerolíneas en la toma de decisiones estratégicas.

El modelado de tópicos es una técnica del PLN utilizada para identificar los temas principales en grandes colecciones de texto. Algoritmos como Latent Dirichlet Allocation (LDA) permiten agrupar palabras en tópicos, proporcionando una visión estructurada de los datos textuales [9]. Sin embargo, técnicas avanzadas como BERTopic, que se basa en BERT (Bidirectional Encoder Representations from Transformers), ofrecen una mejor capacidad para capturar la semántica y la estructura contextual de los datos textuales, mejorando la identificación de tópicos. A diferencia de LDA, BERTopic utiliza embeddings generados por BERT para representar los textos de manera más precisa, permitiendo la detección de temas más sutiles y mejorando la agrupación de comentarios que comparten significado, aunque utilicen diferentes términos[10].

En el caso de las aerolíneas, estas técnicas pueden descubrir patrones recurrentes en los comentarios de los clientes, como problemas con el equipaje, la calidad del servicio a bordo o la puntualidad de los vuelos. Por ejemplo, al analizar miles de comentarios de reseñas, el LDA o BERTopic podría identificar que el tema más mencionado negativamente está relacionado con retrasos, mientras que los comentarios positivos se agrupan en torno a la atención al cliente.

Al combinar el análisis de sentimientos con el modelado de tópicos, las aerolíneas pueden priorizar acciones específicas para mejorar su desempeño y satisfacción del cliente. Este trabajo utilizará datos de reseñas de Skytrax para comprender mejor la percepción de los usuarios sobre las aerolíneas, complementando este análisis con información extraída de tweets.

Herramientas Avanzadas de Análisis Textual

Los Large Language Models (LLMs), como GPT (*Generative Pre-trained Transformer*) y BERT (*Bidirectional Encoder Representations from Transformers*), son modelos de aprendizaje profundo entrenados con grandes volúmenes de datos textuales. Su capacidad para comprender y generar texto con coherencia ha transformado el procesamiento de lenguaje natural (PLN), siendo herramientas clave para tareas como el análisis de sentimientos y el modelado de tópicos.

La arquitectura Transformer, introducida por Vaswani y demás autores [11], constituye la base de los LLMs. Este modelo emplea un mecanismo de *self-attention*, que permite procesar texto en paralelo, capturando relaciones contextuales entre palabras de manera más eficiente que métodos previos como las redes neuronales recurrentes (RNNs) o convolucionales (CNNs). Gracias a estas características, los LLMs han mejorado significativamente el rendimiento en tareas complejas, como la clasificación de texto y la extracción de información.




Figura 2: Arquitectura de transformer. Imagen extraída de [11].

Por ejemplo, BERT introduce un enfoque bidireccional, que captura tanto el contexto anterior como el posterior de una palabra, lo que resulta esencial para interpretar frases ambiguas. Este avance ha permitido aplicaciones más precisas en la industria, como la identificación de emociones en comentarios de usuarios o el análisis de reseñas en la industria aérea.

En este contexto, los embeddings son la base de entrada para modelos como los transformers o más simples. Estas representaciones numéricas que transforman el texto en vectores matemáticos son diseñadas para capturar relaciones semánticas contextuales o estructurales entre los elementos de manera eficiente. Hay distintas técnicas, la más simple de ellas es la técnica “one-hot-encoding”, la cual representa cada palabra como un vector binario en un espacio de dimensiones iguales al tamaño del vocabulario. Luego, otra técnica clásica más avanzada es Word2Vec, el cual se basa en modelos de aprendizaje supervisado y sus palabras con contextos similares tendrán vectores cercanos en el espacio vectorial [12]. Por otro lado la última técnica clásica que se menciona es GloVe, que genera representaciones basadas en la matriz de co-ocurrencia en un corpus grande [13]. Sin embargo, estos enfoques tradicionales carecen de información contextual, lo que limita su capacidad para entender iguales conceptos en distintos contextos

En contraste, los embeddings generados por *sentence-transformers*, basados en BERT y sus variantes como RoBERTa [14], producen representaciones vectoriales a nivel de oración, capturando el significado global del texto al considerar el contexto completo. En este trabajo se ha utilizado el modelo *twitter-roberta-base-sentiment*, una versión optimizada de RoBERTa entrenada en tweets, lo que permite una mejor interpretación de los comentarios de usuarios en redes sociales [15]. Esto permite resolver ambigüedades y mejora tareas como la comparación de similitud semántica, el modelado de tópicos y el análisis de sentimientos. En este trabajo, los embeddings contextuales han sido esenciales para interpretar con mayor precisión los comentarios de los usuarios, facilitando la agrupación de temas y la detección de patrones clave en las reseñas.

2.2 Aprendizaje supervisado

Los modelos predictivos han evolucionado desde la estadística clásica, enfocada en relaciones simples entre variables, hasta los avanzados métodos de aprendizaje automático que se utilizan hoy en día. Gracias a la capacidad computacional y a la gran cantidad de datos, estos modelos permiten no solo analizar patrones históricos, sino también predecir comportamientos futuros y tomar decisiones informadas. Su aplicación se ha expandido a diversos campos, incluyendo la industria aérea, donde ayuda a comprender mejor a los pasajeros y optimizar servicios.

Raíces Estadísticas: Regresión Lineal y Logística

El desarrollo de los modelos predictivos comenzó con la regresión lineal, introducida por Francis Galton en 1886, como una técnica para modelar la relación entre variables continuas [16]. Más adelante, en la década de 1970, se consolidó la regresión logística como un modelo fundamental para resolver problemas de clasificación binaria [17]. Este enfoque se caracteriza por estimar probabilidades y es ampliamente utilizado para comprender cómo las variables explicativas influyen en resultados categóricos. En este proyecto se utiliza la regresión logística para tener una línea base, y compararlo con otros modelos más avanzados.

Avances en Modelos de Predicción

Con la creciente necesidad de analizar datos más complejos y con el aumento de la capacidad computacional, surgieron métodos más avanzados. Uno de ellos, los árboles de decisión, diseñados para dividir conjuntos de datos en subconjuntos basados en reglas simples y permitir una interpretación visual de cómo diferentes factores contribuyen a un resultado. Estos modelos se convirtieron en una herramienta útil para tareas de clasificación y regresión, gracias a su capacidad para identificar patrones y tomar decisiones basadas en variables específicas. Sin embargo, a pesar de su utilidad, los árboles de decisión presentan limitaciones significativas, como su tendencia al sobreajuste cuando se aplican a conjuntos de datos más grandes o con ruido, así como su menor precisión en problemas donde las relaciones entre las variables son complejas o no lineales. Estas limitaciones impulsaron el desarrollo de técnicas más robustas y precisas, como las basadas en ensambles, que combinan múltiples modelos para mejorar el rendimiento general y reducir los riesgos asociados al uso de un único modelo.

Entre estas técnicas destaca Random Forest (bosques aleatorios), introducido por Breiman en 2001, que combinan múltiples árboles de decisión entrenados en diferentes subconjuntos para mejorar la robustez y precisión [18]. Este método de ensamble utiliza un enfoque basado en la aleatorización tanto en la selección de datos como en la construcción de árboles, lo que ayuda a reducir el sobreajuste, una de las principales limitaciones de los árboles de decisión individuales [18]. Los bosques aleatorios se han consolidado como una herramienta ampliamente utilizada en problemas de clasificación y regresión debido a su capacidad para manejar grandes conjuntos de datos con múltiples variables y su relativa simplicidad de implementación.

Por otro lado, algoritmos como XGBoost, desarrollado por Chen y Guestrin en 2016, llevaron las técnicas de ensamble a un nuevo nivel al introducir un método de boosting altamente optimizado [19]. Este método entrena modelos secuenciales donde cada árbol nuevo intenta corregir los errores residuales de los anteriores, maximizando la precisión global del sistema [19]. XGBoost incluye características avanzadas, como el manejo eficiente de datos faltantes, regularización integrada para prevenir el sobreajuste y capacidad para manejar tanto datos estructurados como no estructurados [19]. Estas mejoras generaron que sea una de las herramientas con más aplicaciones en el mundo real, como la predicción de valores financieros y la segmentación de clientes.

Además, ambas técnicas de ensamble comparten la capacidad de identificar la importancia relativa de las variables predictoras en el modelo. Esto permite no solo realizar predicciones precisas, sino también interpretar los resultados, lo que resulta fundamental en escenarios donde es importante comprender el impacto de los factores individuales en el resultado. Por ejemplo, en el contexto de la industria aérea, estos modelos pueden ayudar a determinar qué características del servicio, como la comodidad de los asientos o la atención del personal, tienen un mayor peso en la recomendación de los pasajeros. Esto facilita la toma de decisiones basadas en datos y la implementación de estrategias enfocadas en mejorar la experiencia del cliente.

En este trabajo, se utilizarán tanto Random Forest como XGBoost para evaluar cual de estos modelos ofrecen el mejor rendimiento en términos de precisión y capacidad de generalización. Estos avances en los métodos de ensamble, como el boosting en XGBoost y la aleatorización en Random Forest, permiten abordar de manera más efectiva conjuntos de datos grandes y complejos, lo cual es crucial para mejorar la interpretación y predicción en el análisis de las redes sociales de los usuarios en la industria aérea.

El desarrollo de estas técnicas refleja el avance en la capacidad de los modelos predictivos para abordar problemas cada vez más complejos, equilibrando precisión, eficiencia y capacidad interpretativa. En el caso de la industria aérea, estos modelos son herramientas indispensables para analizar patrones en los datos de pasajeros, anticipar sus necesidades y diseñar estrategias que mejoren los servicios ofrecidos.

2.3 Aprendizaje no supervisado

El aprendizaje no supervisado es un enfoque dentro del aprendizaje automático en el que los modelos analizan datos que no están etiquetados, es decir, sin tener una categoría o respuesta predefinida. El objetivo principal de este enfoque es identificar patrones, estructuras o relaciones dentro de los datos sin la necesidad de supervisión externa. A diferencia del aprendizaje supervisado, donde se utilizan etiquetas para entrenar el modelo, el aprendizaje no supervisado busca explorar los datos y extraer información útil de manera autónoma.

Una técnica común en el aprendizaje no supervisado es el Análisis de Componentes Principales (PCA). PCA es una técnica de reducción de dimensionalidad que transforma un conjunto de

datos con muchas variables correlacionadas en un nuevo conjunto de variables no correlacionadas, llamadas “componentes principales”. Estas combinaciones lineales de las variables originales maximizan la varianza, es decir, capturan la mayor parte de la información posible con un menor número de dimensiones [20]. Esto simplifica los modelos predictivos, eliminando el ruido y la redundancia, mejorando su rendimiento. En el contexto de este trabajo, PCA es utilizado para reducir la dimensionalidad de los datos de las reseñas luego de realizar embeddings. Dado que estos embeddings pueden tener cientos de dimensiones, aplicar PCA permite conservar la información relevante de las reseñas y demás variables, y de esta manera, mejorar la eficiencia computacional de los modelos predictivos.

El proceso de aplicación de PCA incluye varios pasos [20]:

- Se normalizan los embeddings para asegurar que todas las dimensiones tenga la misma escala
- Se calcula la matriz de covarianza y se obtienen sus valores y vectores, determinando la dirección de los componentes principales
- Se selecciona un número óptimo de componentes mediante un análisis de varianza
- Se agregan estos nuevos componentes al dataframe como nuevas columnas y se eliminan los embeddings completos.

Desarrollo

3.1 Metodología

Como fue mencionado anteriormente, en este trabajo se lleva a cabo una prueba de concepto con el objetivo de analizar las reseñas de pasajeros y variables estructuradas relacionadas con aerolíneas con el fin de identificar patrones clave y determinar los factores que impactan en la satisfacción del cliente.

Como se puede observar en la Figura 3, el proceso se organiza en cuatro etapas principales:

- Primera etapa: Recolección de datos, recopilando reseñas de plataformas como Skytrax [2] y Twitter [5], junto con variables complementarias como puntajes de satisfacción, tipo de viajero, ruta, sector en el avión, fecha del vuelo.
- Segunda etapa: Limpieza y transformación de los datos.
 - Se imputan valores faltantes en las variables estructuradas y se aplican procesos de normalización y codificación.
 - Se aplican técnicas de Procesamiento de Lenguaje Natural (PLN) para preparar los textos mediante la eliminación de palabras irrelevantes, tokenización y lematización.
- Tercera etapa: Análisis exploratorio de los datos, donde se examinan las frecuencias de palabras en los textos y se generan gráficos descriptivos para identificar patrones en las variables numéricas y categóricas, permitiendo una primera comprensión de los datos.
- Cuarta etapa: Se desarrolla el modelado de datos, aplicando modelos como BERT para clasificar los sentimientos en positivos, negativos o neutros, y algoritmos de aprendizaje automático como Random Forest y XGBoost para predecir la recomendación del pasajero y determinar las variables con mayor impacto en la satisfacción.

Este proceso integral permite visualizar los resultados y comparar el desempeño de United Airlines con sus competidores nacionales, facilitando la identificación de oportunidades de mejora.



Figura 3: Esquema gráfico de las etapas del desarrollo del trabajo. Imágen de elaboración propia.

3.2 Recolección de datos

Para llevar a cabo esta prueba de concepto, se utilizaron dos bases de datos provenientes de Kaggle, que representan de manera adecuada la información de la plataforma Skytrax y de Twitter, enfocándose en las aerolíneas nacionales de Estados Unidos.

La primera base corresponde a los datos de Skytrax [2], recopilados entre los años 2012 y 2018. Algunas de las variables que tiene el dataset son las puntuaciones de 1 a 5 para puntuar factores como la comida y bebidas en el vuelo, entretenimiento, servicio a bordo, servicio en tierra, si vale el servicio comparándolo con el precio (Anexo 2). Esta base contiene reseñas realizadas por pasajeros sobre aerolíneas de todo el mundo, por lo que fue necesario aplicar un proceso de filtrado para seleccionar únicamente las aerolíneas nacionales dentro de Estados Unidos. Una característica importante de esta base es la presencia del indicador "*Trip Verified*", que asegura la veracidad de las reseñas, ya que los pasajeros deben demostrar haber realizado el vuelo para poder escribir una opinión. Esto agrega un nivel de fiabilidad a los datos, reduciendo el riesgo de reseñas falsas y garantizando un análisis más preciso.

La base original contiene 131.895 filas, pero presenta varios problemas de calidad. Muchas de estas filas contienen nulos en todas las columnas, lo que probablemente se debe a un error en la recolección de datos desde la página web. Además, como fue mencionado anteriormente, la base incluye información de aerolíneas de otros países, siendo irrelevante para el análisis. Luego del proceso de limpieza que será detallado más adelante, se reduce a 12.150 filas, es decir, 119.745 filas son consideradas ruido para nuestro análisis.

La segunda base corresponde a datos de Twitter del año 2015, que contienen menciones a aerolíneas estadounidenses. Además de los tweets incluye información adicional como la fecha y hora del tweet, así como la cantidad de retweets (Anexo 3), lo que permite evaluar la relevancia y el alcance de las publicaciones. Esta base proporciona una perspectiva complementaria a las reseñas de Skytrax, capturando opiniones más inmediatas y espontáneas de los pasajeros en redes sociales.

Sin embargo, es importante tener en cuenta que los datos corresponden a 2015, lo que significa que las opiniones y experiencias de los pasajeros pueden haber cambiado desde entonces como también la situación del mercado aéreo, lo que podría limitar la aplicabilidad directa de los resultados. A pesar de esto, los datos servirán como prueba de concepto, mostrando cómo este tipo de análisis puede ser aplicado a datos más recientes y utilizarse para obtener la perspectiva actual de los clientes y su experiencia.

En cuanto a la calidad de los datos, antes de la depuración, la base contenía 14.640 filas de tweets. Sin embargo, luego del proceso de limpieza, se redujeron los registros a 11.513. Esto quiere decir que 3.127 filas fueron descartadas debido a la presencia de valores irrelevantes o nulos. Esto implica que el ruido representaba un 21,3% del total de los datos.

Adicionalmente, se utilizó una tercera base de datos que contiene información detallada sobre aeropuertos a nivel global [4]. Esta base incluye atributos como coordenadas geográficas, nombre del aeropuerto, ciudad, país, continente y el código IATA. La información de esta base será posteriormente unificada con los datos de Skytrax, permitiendo realizar análisis geográficos que faciliten la identificación de patrones relacionados con la ubicación de los vuelos y los aeropuertos más relevantes en el análisis.

Todas las bases de datos fueron almacenadas en Google Cloud Platform (GCP). Esta solución en la nube permite un manejo eficiente de grandes volúmenes de datos, asegurando escalabilidad y disponibilidad en las etapas posteriores del análisis. Sin embargo, se decidió continuar las siguientes etapas de manera local debido a la facilidad que esto ofrecía para su desarrollo. En conjunto, estas dos bases permiten construir un conjunto de datos representativo y confiable, que combina opiniones verificadas de pasajeros con contenido generado en tiempo real en redes

sociales. Posteriormente, los datos serán procesados y analizados para identificar patrones, modelar sentimientos y extraer información relevante sobre la experiencia de los pasajeros con las aerolíneas nacionales en Estados Unidos.

3.3 Limpieza y transformación de datos

En el marco del proceso de preparación de los datos, se realizaron una serie de transformaciones exhaustivas tanto para corregir inconsistencias como para garantizar la integridad y utilidad del dataset. Estas transformaciones se llevaron a cabo en las tres bases de datos: por un lado, la base de aeropuertos y la base de reseñas de pasajeros provenientes de Skytrax y por el otro, la base de Twitter.

Base de Datos de Aeropuertos

La base de datos de aeropuertos contenía información sobre códigos IATA, nombres de aeropuertos, ciudades, países y coordenadas geográficas. Durante el análisis inicial (Anexo 4), se detectaron varios problemas de calidad que incluían valores nulos, nombres de países mal escritos y aeropuertos duplicados con ligeras variaciones en algunas de sus variables. Por ello, mediante BigQuery, se realizaron algunas transformaciones para abordar estas cuestiones:

- **Tratamiento de nulos**: se eliminan tres variables, “*local_code*”, “*elevation_ft*” y “*gsp_code*”, ya que además de ser variables con muchos nulos, son variables innecesarias para el análisis. Luego de bajar drásticamente los nulos, se corrige los nulos del “*continente*”, el cual son todos de América del Norte y su abreviatura “NA”, generaba inconvenientes al cargar la base ya que “NA” se tomaba como nulo, es por ello, que se decidió pasar todos los nombres de los continentes a sus nombres completos. Sucedió esta misma situación para el código del país Namibia, donde el código es NA. Como nuestra base en su mayoría está abocada a vuelos entre ciudades de Estados Unidos, y algunos destinos en el exterior, y Namibia no es un lugar considerablemente importante para el objetivo de este trabajo, se decidió eliminar las filas del país.

- Corrección de nombres mal escritos: Los países que contienen “of” por ejemplo “Bolivarian Republic of Venezuela” estaban truncados, de la siguiente forma: “Venezuela, Bolivarian Republic of”. Es por ello que se corrigieron todos los países que estaban mal escritos.

- Eliminación de duplicados: Se identificaron varias locaciones en por ejemplo la ciudad de Seattle, para simplificar la base, se eliminaron las filas que tenían en la variable “*type*” las opciones cerrado y helipuertos ya que no aportan información para el objetivo de este proyecto. Luego se organizó la base teniendo en cuenta el tipo de aeropuerto porque en caso de que en la ciudad hayan varios aeropuertos, la prioridad es el aeropuerto grande ya que hay aeropuertos privados que son pequeños, pero a la vez no se pueden borrar los aeropuertos pequeños porque hay ciudades chicas que solo tienen un aeropuerto y es pequeño.

Con esta limpieza, la base de datos de aeropuertos quedó lista para ser integrada con el resto del proyecto, sirviendo como referencia para la asignación de códigos IATA y el enriquecimiento del dataset principal.

Base de Datos de Reseñas Skytrax

La base de reseñas de Skytrax [2] requirió un abordaje más complejo (Anexo 5), dada la variedad de inconsistencias y la presencia de valores faltantes en múltiples columnas. Las transformaciones realizadas se detallan a continuación:

Transformación en la columna route:

- En primer lugar, se buscó extraer la ruta en la variable “*customer_review*”. Esto implicó la implementación de modelos basados en patrones de texto y palabras clave para identificar ciudades de origen y destino.
- Luego de la extracción de datos de “*customer_review*”, se transformaron los nombres de ciudades en códigos IATA utilizando la base de aeropuertos.

Transformación en la columnas “cabin” y “traveller_type”:

- En primer lugar, se aplicaron estrategias avanzadas de imputación para abordar los valores nulos, manteniendo consistencia con las políticas y características propias de cada aerolínea.

- Para la variable “*cabin*”, se utilizó un análisis detallado de las reseñas para identificar palabras en “*customer_review*” que permitieran asignar valores como Economy o Business. Complementariamente, se realizaron ajustes manuales en casos específicos para asegurar coherencia con las ofertas reales de cabina.
- Para “*traveller_type*” fue procesada mediante una clasificación basada en palabras clave identificadas en los comentarios, priorizando la detección de viajeros familiares o de negocios de manera jerárquica.

Transformación en la columnas “value_for_money” y “overall”:

Los valores nulos fueron imputados utilizando un enfoque condicional basado en otras variables.

Por ejemplo:

- Si “*recommended*” era 1 y “*value_for_money*” tenía un puntaje alto, se asignó un valor coherente en “*overall*”.
- En casos extremos o sin contexto suficiente, se utilizó la mediana de la columna para asegurar la completitud.

Por otro lado, se identificaron variables irrelevantes, como “*entertainment*”, cuyo alto porcentaje de valores nulos limitaba su utilidad analítica. Estas variables fueron eliminadas para simplificar el modelo y evitar ruido en los datos. En contraste, variables como “*ground_service*” fueron imputadas de manera más detallada, utilizando medianas calculadas por grupos definidos por aerolínea, tipo de viajero y cabina. Este enfoque permitió mantener la riqueza informativa del dataset al tiempo que se reducían significativamente los valores nulos.

Tras realizar la imputación de nulos se crearon nuevas variables derivadas de las columnas existentes para enriquecer el análisis. Entre ellas se incluyeron:

- Distancia entre aeropuertos: calculada a partir de las coordenadas geográficas de origen y destino mediante fórmulas geodésicas.
- Tiempo estimado de vuelo: desarrollado a partir de las distancias, utilizando un modelo simplificado que estima el tiempo de vuelo en minutos considerando la velocidad promedio de los aviones comerciales.

- *Food_service*: una columna diseñada para distinguir si existen datos disponibles relacionados con el servicio de alimentos. Esta variable permite identificar vuelos en los que se ofrece comida o snacks, estableciendo un valor de 1 en casos positivos. Posteriormente, en la columna "*food_bev*", se asignaron puntajes siempre que "*food_service*" tuviera un valor de 1.

Teniendo en cuenta que entre las aerolíneas seleccionadas hay aerolíneas "*low-cost*". Las aerolíneas de bajo costo generalmente no ofrecen comida gratuita en sus vuelos, lo que refuerza la importancia de analizar esta característica. Por ejemplo, Spirit Airlines no incluye comidas gratuitas en su servicio y solo ofrece snacks y bebidas disponibles para la venta. De manera similar, Frontier Airlines tampoco proporciona comidas gratuitas, aunque cuenta con opciones de compra a bordo. En el caso de Southwest Airlines, aunque no ofrece comidas, usualmente proporciona snacks gratuitos y bebidas sin costo adicional, destacándose por este diferencial en su servicio. Estas particularidades reflejan las estrategias de estas aerolíneas para mantener costos bajos, lo que las distingue de las aerolíneas tradicionales.

En el proceso de preparación del dataset, también se realizó un paso fundamental: la anonimización de datos. Este procedimiento es esencial para proteger la privacidad de los individuos y garantizar que la información personal contenida en el conjunto de datos no pueda ser utilizada para identificar directamente o indirectamente a las personas. La anonimización transforma datos sensibles en un formato no identificable, cumpliendo así con las normativas de privacidad vigentes y permitiendo el análisis seguro de los datos sin comprometer la integridad ni la seguridad de la información personal..

En el análisis del dataset, se identifica una desproporción significativa en la distribución de la variable objetivo (Target). Como se observa en la Figura 4, el 74% de los casos corresponde a la categoría 'Sí' recomienda, mientras que sólo un 26% pertenece a la categoría 'No' recomienda. Esta desigualdad sesga el aprendizaje del modelo hacia la clase mayoritaria, limitando su capacidad para predecir correctamente la clase minoritaria y afectando su rendimiento en escenarios reales más equilibrados.

Distribución de Recomendaciones antes de balancear




Figura 4: Distribución de recomendaciones antes de balancear el dataset. Imágen de elaboración propia.

Para mitigar este problema, se aplica oversampling, técnica para equilibrar la distribución de las clases y en este caso, para lograrlo se crean datos sintéticos. Este procedimiento genera observaciones artificiales para la clase minoritaria, equilibrando la distribución de las categorías en el dataset. Al incorporar estos datos sintéticos, el modelo aprende de forma más equitativa las características de ambas clases, mejorando su precisión y capacidad de generalización. Más adelante, se demuestra que esta estrategia logra un balance adecuado en el dataset, contribuyendo a un análisis más justo y balanceado, especialmente en casos donde ambas categorías tienen un impacto significativo en la toma de decisiones.

Por último, en el proceso de limpieza de datos, se realizó una depuración básica de la columna “customer_review”, que contiene comentarios textuales de los pasajeros. Dado que esta información es fundamental para el análisis, se decidió eliminar las filas donde no existían reseñas, ya que dichas observaciones carecían de valor analítico significativo al no incluir opiniones de los pasajeros. Además, se normaliza el texto convirtiéndolo en minúsculas y se eliminaron espacios en blanco adicionales, asegurando un formato uniforme en toda la columna.

Base de Datos de Twitter

Por otro lado, en el proceso de limpieza y transformación de datos de la base de Twitter [5], se llevó a cabo un tratamiento más simple debido a la sencillez de este conjunto de datos (Anexo 6).

En primer lugar, se eliminaron los registros duplicados para garantizar la unicidad de las observaciones. Respecto al tratamiento de valores nulos, se decidió eliminar columnas que no eran relevantes para los objetivos del análisis, como “*negativereason_confidence*”, “*airline_sentiment_gold*”, “*negativereason_gold*”, “*tweet_coord*”, “*tweet_location*” y “*user_timezone*”. Estas columnas no aportan información significativa y su eliminación simplificó la estructura del dataset. Con este ajuste, los valores nulos sólo permanecieron en la columna “*negative_reason*”. Esta columna es interesante para el análisis exploratorio, pero no necesaria para la construcción de modelos predictivos. Por esta razón, en lugar de eliminar las filas con valores faltantes, lo que habría resultado en la pérdida de datos útiles en otras variables, se decidió completar los nulos con "N/A". Este enfoque permitió conservar todas las observaciones relevantes para los modelos y mantener la columna disponible para análisis adicionales.

La columna “*text*”, que contiene los tweets, fue sometida a las siguiente de transformaciones para garantizar su limpieza y uniformidad:

- Se eliminaron palabras vacías (stopwords) para reducir el ruido en los datos y enfocarse en las palabras con mayor relevancia semántica.
- Se eliminaron URLs, signos de puntuación y menciones de usuarios (@username), elementos que no aportan valor al análisis como también se eliminaron emojis para evitar interpretaciones inconsistentes.
- Como parte de la normalización del texto, se expandieron las contracciones comunes en inglés para asegurar claridad, separando además palabras alfanuméricas para una mejor tokenización.
- Se limitaron las repeticiones excesivas de caracteres consecutivos y se eliminaron aquellos no alfabéticos, asegurando un formato homogéneo y claro en el texto procesado.

Asimismo, se realizó una separación de la columna que contenía la fecha y hora del tweet, generando dos columnas distintas: una para la fecha y otra para la hora. Esto facilitó la posibilidad de identificar patrones temporales más específicos. Con estas transformaciones y limpiezas, se logró obtener un dataset optimizado, consistente y completo, preparado tanto para análisis exploratorios como para la implementación de modelos.

3.4 Análisis exploratorio de datos (análisis y visualización de datos)

Se realizó un análisis de outliers en las distintas variables numéricas y se confirmó la ausencia de valores atípicos. Todos los valores de los puntajes estaban dentro del 1 al 5 excepto la variable overall que tiene sus valores entre el 1 al 10 (Figura 5). Al no contar con valores atípicos, no fue necesario realizar un tratamiento para ellos.




Figura 5: Distribución y boxplot de “overall”. Imágen de elaboración propia.

El análisis exploratorio y la evaluación del balanceo del dataset de Skytrax permitieron identificar transformaciones significativas que mejoraron tanto la calidad como la representatividad de los datos (Anexo 7). Inicialmente, la variable objetivo “*recommended*” presentaba un desbalance notable, con un 74% de reseñas negativas y solo un 26% de positivas (Figura 3). Este desequilibrio limitaba la capacidad de los modelos predictivos para aprender de ambas clases de manera equitativa. Mediante la técnica de oversampling, se logró una distribución perfectamente equilibrada, con el 50% de reseñas en cada categoría. Este ajuste no solo asegura una representación justa, sino que también mejora la capacidad de generalización del modelo. Los gráficos comparativos confirmaron que el aumento de las reseñas positivas no afectó la integridad del dataset, manteniendo la distribución general de las variables clave.

Entre las variables analizadas, el puntaje general (“*overall*”) destaca por ser una métrica central para evaluar la satisfacción de los pasajeros. En el dataset original, el puntaje promedio era de 3,41 en una escala de 1 a 10, reflejando una percepción predominantemente negativa. Tras el

balanceo, este promedio aumentó a 4,98, un cambio coherente con la generación de datos sintéticos enfocados en reseñas positivas. A pesar de este incremento, la estructura de la distribución se mantuvo consistente, siendo la puntuación general de 1 el valor más frecuente en ambos datasets. Este resultado garantiza que las características originales de los datos no se distorsionaron.




Figura 6: Distribución de “overall”, antes y después del balanceado. Imágen de elaboración propia.

La comodidad de los asientos (“*seat_comfort*”) también reflejó tendencias interesantes. En el dataset original, predominaban las calificaciones bajas, con una mediana de 2, evidenciando una percepción de incomodidad generalizada. En el dataset balanceado, la mediana subió a 3, y se observó una mayor dispersión hacia calificaciones más altas, lo que indica una representación más equilibrada de las opiniones positivas. De manera similar, se observa en la Figura 7, una mejora en las valoraciones altas de relación calidad-precio (“*value_for_money*”), aunque se mantuvo la tendencia hacia puntuaciones bajas, con el valor más frecuente en 1 en ambos datasets.




Figura 7: Distribución de “*value_for_money*”, antes y después del balanceo. Imágen de elaboración propia.

El análisis por aerolínea reveló que el proceso de balanceo no alteró la proporción de reseñas por cada compañía, preservando la diversidad del dataset. Aerolíneas como Virgin America y Alaska Airlines sobresalen con las mejores calificaciones generales y tasas de recomendación, mientras que United Airlines y Spirit Airlines se posicionan en los niveles más bajos.

El balance de clases y el análisis exploratorio demuestran que el dataset ahora es más representativo y adecuado para el entrenamiento de modelos predictivos. Las distribuciones clave se mantuvieron intactas, mientras que la inclusión de datos sintéticos permite un aprendizaje más equilibrado y robusto. Este enfoque asegura que los modelos resultantes puedan capturar patrones relevantes y contribuir a identificar mejoras estratégicas en la experiencia del cliente.

Además, una de las relaciones identificadas fue la alta correlación entre la probabilidad de recomendación (“*recommended*”) y la calificación general (“*overall*”). Esta correlación, que alcanzó un coeficiente de 0,92, sugiere que los pasajeros basan su decisión de recomendar principalmente en su percepción global de la experiencia de vuelo. Aerolíneas como Virgin America y Alaska Airlines, con altos puntajes en ambas métricas, sobresalen por su experiencia positiva constante. En contraste, United Airlines, con puntajes bajos tanto en *overall* como en “*recommended*”, evidencia áreas de mejora significativas, especialmente en aspectos relacionados con la satisfacción general del cliente.




Figura 8: Relación entre “Overall” y “Recommended” por Aerolínea. Imágen de elaboración propia.

Otro hallazgo proviene de la variable “*seat_comfort*”, que mostró una correlación de 0,80 con “Overall”, lo que resalta como el confort de los asientos impacta directamente la percepción global de los pasajeros. Aerolíneas como Delta y Virgin America, que obtuvieron puntuaciones más altas en esta dimensión, lograron mejores evaluaciones generales. Lo interesante de esta correlación es que, aunque el confort de los asientos puede parecer un factor obvio, su peso en la calificación general es significativo, sugiriendo que es un aspecto crítico en la experiencia del pasajero.

Por otro lado, la variable “*value_for_money*” presenta la mayor correlación con la calificación general, destacando que los pasajeros valoran especialmente si el servicio justifica el costo pagado. Este hallazgo va más allá de la calidad de los servicios en sí, señalando que el valor percibido puede ser tan relevante como otros factores más tangibles. Es por ello que uno de los objetivos clave debe ser, a través de la mejora de factores como el servicio, la comodidad del asiento y la comida, asegurar que el valor del pasaje se vea reflejado en la calidad del vuelo.

Finalmente, la percepción de ciertos servicios, como el servicio de cabina (“*cabin_service*”), con una correlación de 0,83 respecto a la clasificación general, refuerza la idea de que la calidad de la

atención durante el vuelo tiene un impacto directo en la satisfacción general, incluso cuando aspectos como el confort o la puntualidad puedan ser más evidentes. Este hallazgo refuerza la necesidad de que las aerolíneas inviertan en mejorar la atención al cliente durante el vuelo, ya que influye directamente en la experiencia percibida.

En cuanto a “*ground_service*”, con una correlación de 0,73 con la calificación general, resulta interesante porque aunque los pasajeros suelen estar impacientes y nerviosos antes de subir a un avión, este aspecto no tienen tanta correlación como otros factores como el confort o el servicio a bordo. Sin embargo sigue siendo relevante y debe ser considerado en las estrategias de mejora, ya que contribuye a la primera impresión de la experiencia del pasajero




Figura 9: Mapa de Calor de Correlaciones entre *Overall* y Otras Variables. Imágen de elaboración propia.

En conjunto, estos resultados no solo demuestran la efectividad del balanceo del dataset, sino que también destacan áreas clave que las aerolíneas, especialmente United Airlines, deben priorizar para mejorar la experiencia del cliente y aumentar la probabilidad de recomendación. Estos hallazgos servirán como base para las siguientes etapas de modelado y análisis estratégico.

3.5 Desarrollo de modelos y resultados

En esta sección se describe la implementación de los modelos utilizados para analizar y predecir aspectos clave de la experiencia de los pasajeros.

3.5.1 Análisis de sentimientos y tópicos de temas de Skytrax

En esta parte de la solución, se analiza la base de datos de Skytrax utilizando técnicas de procesamiento de lenguaje natural (PLN) para identificar los sentimientos predominantes y los tópicos principales presentes en las reseñas de los usuarios (Anexo 8). Este enfoque tiene como objetivo comprender las áreas de mayor satisfacción e insatisfacción, así como identificar patrones clave en las opiniones de los pasajeros.

En un primer lugar, se utilizó el modelo **VADER (Valence Aware Dictionary and sEntiment Reasoner)** para realizar un análisis inicial de sentimientos en las reseñas de los usuarios. Este enfoque lexicón-basado clasifica los textos en sentimientos positivos, negativos y neutros, asignando una puntuación que refleja la intensidad emocional de cada reseña. VADER fue el primer modelo elegido debido a su simplicidad y rapidez, permitiendo un análisis preliminar sobre los datos. Este modelo es adecuado para textos cortos e informales como las reseñas. Sin embargo, el modelo presenta ciertas limitaciones. Al centrarse en palabras claves, VADER puede analizar solo una parte de la reseña sin considerar el contexto completo, dificultando la clasificación precisa del sentimiento. Esto es especialmente relevante en casos donde se emplean matices sutiles, como el sarcasmo o ironía, que el modelo no capta adecuadamente.

Para abordar estas limitaciones y mejorar la precisión del análisis, se implementó un modelo preentrenado basado en **RoBERTa** ('twitter-roberta-base-sentiment') utilizando la librería Hugging Face[15]. A diferencia de VADER, RoBERTa es un modelo basado en transformers que considera el contexto completo de la reseña, permitiendo detectar con mayor precisión matices en el lenguaje, como ironía, sarcasmo y contradicciones. Aunque su utilización implica un costo computacional grande y requiere un tiempo considerable para procesar grandes volúmenes de datos, su capacidad para interpretar la estructura semántica de los textos lo convierte en una opción más robusta para el análisis en profundidad.

En cuanto al manejo de los sentimientos ambiguo, los resultados obtenidos en los ejemplos mostraron que BERT tuvo una mejor precisión al identificar el sentimiento de textos complejos en comparación con VADER:

Reseña resumida	Sentimiento VADER	Sentimiento BERT
El usuario había reservado un vuelo a Hong Kong con Flight Network. Durante el vuelo de ida, la aeronave no tenía entretenimiento ni enchufes para cargar el laptop. En el vuelo de regreso, la conexión fue cambiada sin previo aviso, pasando de San Francisco a Chicago, lo que provocó una demora de 9 horas y la pérdida de un día de trabajo.	Neutral	Negativo
El pasajero eligió una aerolínea porque el vuelo era más corto. Sin embargo, al llegar al mostrador, se le cobró \$45 por una maleta de mano, lo cual nunca había sucedido en vuelos previos. Esto le causó frustración, ya que si hubiera sabido del cargo, habría empacado de manera diferente.	Negativo	Neutral
El usuario voló de Austin a Durango con escala en Dallas. Aunque llegaron a tiempo para la conexión, el vuelo fue retrasado y al llegar a la puerta de embarque, ya estaba cerrada. Además, las personas en lista de espera fueron prioritarias, a pesar de que el pasajero había comprado el boleto meses antes. El pasajero expresó su frustración por la experiencia, mencionando que aunque las azafatas fueron amables, no pudieron hacer nada por ellos.	Neutral	Negativo

Figura 10: Ejemplos de reseñas resumidas del Anexo 9 con el texto original de la reseña. Tabla de elaboración propia.

- **Ejemplo 1:** Aunque la reseña expresa claramente frustración por los retrasos y la falta de información, VADER lo clasifica como neutral, posiblemente porque no detecta de manera explícita un lenguaje altamente emocional. En cambio, BERT identifica la frustración y la queja sobre el tiempo perdido, etiquetando el sentimiento como negativo.
- **Ejemplo 2:** Si bien la reseña menciona la molestia por el cargo adicional por el equipaje de mano, VADER la clasifica como negativa debido al tono de queja implícito. Por otro lado, BERT lo clasifica como neutral, posiblemente porque no considera que la queja sea lo suficientemente fuerte como para justificar una etiqueta negativa.

- **Ejemplo 3:** A pesar de que la reseña incluye un comentario positivo sobre la amabilidad de los auxiliares de vuelo, la crítica general hacia la mala experiencia hace que VADER lo clasifique como neutral. BERT, en cambio, clasifica la reseña como negativa debido a las quejas explícitas y la expresión de insatisfacción general ("worst flight experience ever").

Estos ejemplos destacan como BERT, al considerar el contexto completo y detectar los matices emocionales implícitos, genera una clasificación más precisa en comparación con VADER. Mientras que VADER puede simplificar la interpretación de sentimientos y no captar estos matices, BERT es capaz de identificar de manera más efectiva la complejidad emocional de los textos, proporcionando una visión más exacta del sentimiento dominante.

A partir de los resultados del análisis de sentimientos, se filtraron las reseñas positivas y negativas para identificar los temas más recurrentes en cada categoría. Luego se aplicó un *análisis de tópicos* para detectar las principales preocupaciones y aspectos destacados dentro de cada grupo de sentimiento.

Para el modelado de tópicos, se aplicó el algoritmo de **Latent Dirichlet Allocation (LDA)** para el modelado de tópicos. Esta técnica permitió agrupar palabras clave en temas específicos, destacando los aspectos más discutidos por los pasajeros, como la comodidad de los asientos, el servicio al cliente y la puntualidad de los vuelos. Sin embargo, es importante señalar que LDA presenta limitaciones al capturar el significado semántico en textos cortos como reseñas, debido a su enfoque basado en la co-ocurrencia de palabras.

Para abordar esta limitación, se realizó la implementación de **BERTopic**, un modelo más avanzado que utiliza embeddings de modelos preentrenados como BERT para mejorar la captura de las relaciones semánticas y agrupar los temas de manera más precisa. Los temas generados por BERTopic y LDA parecen ser similares en términos de los aspectos clave de la experiencia de vuelo, pero cada modelo los agrupa de manera distinta.

Diferencias en la agrupación:

- BERTopic tiende a agrupar temas de una forma más flexible, abarcando diferentes aspectos de una experiencia de vuelo en cada tema (por ejemplo, un tema sobre "tiempo" puede incluir tanto retrasos como duración de vuelos).
- LDA es más estructurado y puede identificar más detalles granulares, con diferentes temas para aspectos específicos (por ejemplo, un tema sobre "retrasos" y otro separado sobre "equipaje").

En la sección de resultados, se utilizaron los valores de LDA, ya que, aunque BERTopic genera temas más precisos semánticamente, LDA tiene un menor costo computacional.

Resultados

En primer lugar, se desarrolló un modelo de análisis de sentimientos, seguido por un análisis de tópicos. El análisis de la relación entre la polaridad de las reseñas y la recomendación muestra diferencias clave entre VADER y BERT.

- VADER muestra una fuerte correlación entre reseñas negativas y la falta de recomendación, pero también clasifica todas las reseñas neutrales como "No Recomendación", lo que podría subestimar la polaridad negativa. Las reseñas positivas, aunque correlacionadas con la recomendación, no tienen una proporción tan alta en comparación con las negativas para "No Recomendación".
- BERT, en cambio, captura mejor los matices emocionales, mostrando una mayor proporción de reseñas positivas recomendando el servicio. Además, las reseñas neutrales tienen un balance más equitativo entre "Recomienda" y "No Recomendación", reflejando una interpretación más precisa de los tonos mixtos.




Figura 11: Relación entre Polaridad (Vader y BERT) si recomienda o no. Imagen de elaboración propia.

Como se destacó en el párrafo anterior, el modelo BERT demostró una mayor precisión al clasificar las reseñas como positivas o negativas en comparación con el modelo VADER. Algunos ejemplos de reseñas en las que VADER y BERT ofrecieron resultados diferentes se incluyen en el Anexo 10. En todos estos casos, BERT demostró ser más preciso. Por ejemplo, en una de las reseñas, se podía leer claramente la frase: *"I do not recommend the airline"*. Aunque el contexto indica claramente una opinión negativa, VADER clasificó la reseña como neutral, mientras que BERT, comprendiendo el verdadero significado, la categorizó correctamente como negativa.

Por esta razón, y como se mencionó en el desarrollo, se utilizó la variable generada por BERT ("bert_sentiment") para el análisis de tópicos, determinando el número óptimo de tópicos necesarios tanto para reseñas positivas como negativas, considerando a United Airlines y también a la competencia. En todos los casos, el número óptimo de tópicos fue dos. Para determinar este número, se aplicó el algoritmo LDA con diferentes cantidades de tópicos (2, 3 y 5), evaluando cuál ofrecía una mejor separación y claridad de los temas. Se seleccionó el número óptimo en función de la coherencia del modelo y la relevancia de los tópicos que generó.

Para el análisis de tópicos en los resultados, se utilizó Latent Dirichlet Allocation (LDA) debido a su menor costo computacional y a que proporciona respuestas suficientemente detalladas. Los resultados se presentan a continuación de manera desglosada.

United Airlines

- **Reseñas negativas:**

- Topico 1

- Palabras clave: *hours, time, service, told, delayed, customer, airport, fly, hour, gate, day, connecting, said, minutes, pm, luggage, cancelled.*
- Experiencias frustrantes de los pasajeros, retrasos significativos, conexiones perdidas y falta de transparencia por parte de la aerolínea.
- Ejemplo representativo de las palabras clave: cliente expresa su insatisfacción con United Airlines debido a retrasos de casi tres horas en su vuelo, lo que resultó en la pérdida de conexiones y explicaciones contradictorias sobre las razones del retraso. Además, se mencionan vuelos cancelados sin justificación clara, una atención al cliente deficiente, especialmente en Denver, y el envío de equipaje al destino equivocado. La compensación ofrecida fue considerada insuficiente, lo que llevó al cliente a concluir que no volverá a volar con United, destacando la falta de preocupación por sus pasajeros (ejemplo original en el Anexo 11).

- Topico 2

- Palabras clave: *seat, seats, service, food, economy, class, entertainment, crew, like, time, staff, bag, pay, business, cabin, attendants, passengers, hour, fly, carry.*
- Experiencias a bordo del vuelo, comodidad de los asientos, la calidad del servicio y la comida,

- Ejemplo representativo: Un pasajero relata su experiencia en un vuelo de Houston a Honolulu, quejándose de la falta de comidas gratuitas en un trayecto de 8 horas, la ausencia de pantallas de entretenimiento y el espacio limitado de los asientos en clase económica. Aunque los asientos eran cómodos y bien diseñados, el alto costo de la comida y la ausencia de servicios gratuitos hicieron que el vuelo se percibiera como el de una aerolínea de bajo costo. Si bien la tripulación fue educada, la falta de atención a detalles como las comidas generó una gran decepción (Anexo 12).

- **Reseñas positivas:**

- Topico 1

- Palabras clave: *service, friendly, staff, time, great, crew, hours, day, fly, went, hour, comfortable, attendants, offer.*
- Atención y servicio al cliente, amabilidad del personal en el aeropuerto.
- Ejemplo representativo: Experiencia de un pasajero que agradece la amabilidad y el apoyo del personal de United Airlines durante su viaje a Nueva York. A pesar de un error en la fecha de su vuelo, el equipo de United resolvió la situación con profesionalismo y empatía. Este trato fue esencial para reducir el estrés del pasajero, especialmente dado que se encontraba en tratamiento médico, y destacó profundamente la calidad de la atención recibida en un momento tan delicado (Anexo 13).

- Topico 2

- Palabras clave: *good, service, seat, food, time, seats, crew, economy, comfortable, nice, class, new, great, entertainment, cabin, friendly, experience, business, aircraft, staff.*
- Experiencia general, abordando aspectos como el avión, el personal, la comodidad y los servicios ofrecidos

- Ejemplo representativo: Un pasajero relata su experiencia en la clase Business Polaris de United Airlines en un vuelo de Lisboa a Newark. Destaca la comodidad de los asientos, que se reclinan completamente para un buen descanso, y la calidad de los artículos de cortesía. Además, menciona la pantalla de entretenimiento de buen tamaño, la temperatura agradable en la cabina y la oferta de dos mantas, lo que mejoró la experiencia. Aunque señala pequeños inconvenientes, como la falta de almacenamiento en los asientos y la calidad del segundo plato del menú, resalta que el producto Polaris tiene gran potencial y podría convertirse en un referente en la clase Business con algunos ajustes (Anexo 14).

Competencia

Aerolinea	Temas Negativos	Palabras clave	Descripción
American Airlines	Temático 1	time, hours, service, told, customer, delayed, gate, airport, fly, hour, dallas, got, day, minutes, connecting, check, said, experience, pm, people	Quejas sobre demoras y retrasos en los vuelos, falta de información en el aeropuerto, especialmente con puertas de embarque y horarios.
	Temático 2	seats, seat, service, class, food, crew, staff, passengers, cabin, new, old, aircraft, attendants, time, good, entertainment, miami, business, hour, fly.	Quejas sobre la comodidad de los asientos, calidad de la comida y el entretenimiento, y el estado de los aviones.
Delta Airlines	Temático 1	hours, service, time, delayed, airport, fly, got, customer, told, hour, staff, gate, food, experience, air, new, flying	Críticas sobre retrasos, problemas con el servicio, y la información incorrecta en el aeropuerto.
	Temático 2	seat, moscow, seats, told, baggage, day, service, arrived, time, gate, clothes, phone, bags, customer, amsterdam, new, left, boarding, return	Problemas con el equipaje y pertenencia de los pasajeros y la atención al cliente en vuelos internacionales.

Figura 12: Tópicos negativos de la competencia. Tabla de elaboración propia.

Tanto American Airlines como Delta Airlines comparten un problema común relacionado con las demoras y los retrasos, lo cual es una de las principales quejas de los pasajeros en ambos casos. Además, ambas aerolíneas enfrentan críticas sobre la falta de información proporcionada en los aeropuertos, lo que genera frustración en los pasajeros.

United Airlines también se ve afectada por problemas similares en cuanto a retrasos y logística. Por lo tanto, mejorar la gestión de los vuelos y garantizar una comunicación efectiva con los pasajeros no sólo reducía la frustración sino que proporcionará a United Airlines una ventaja competitiva al ofrecer un servicio más eficiente y transparente.

3.5.2 Modelos de clasificación de recomendación

Se implementaron dos enfoques de modelado para abordar el problema de predecir si los pasajeros recomendarían el servicio (Anexo 15). El objetivo fue explorar diferentes niveles de complejidad en los modelos para determinar cuál ofrece mejores resultados, teniendo en cuenta tanto las variables estructuradas como la información contenida en las reseñas de los usuarios.

Primer modelo: Regresión logística

El primer modelo, diseñado como una solución más sencilla y básica:

- Variable objetivo: “*recommended*” (Variable balanceada, con 50% de reseñas que recomiendan la aerolínea y 50% que no lo hacen).
- Variables predictoras: todas las columnas excepto “*customer_review*”.
- División del conjunto de datos: 70% para entrenamiento, 15% para validación y 15% para prueba.

Este modelo sirvió como línea base para la evaluación del rendimiento, por lo que no se ajustaron los hiperparámetros y se mantuvieron los valores predeterminados del algoritmo.

Segundo modelo: Regresión XGBoost con embeddings textuales

En el segundo modelos incorpora tanto las variables estructuradas como los embeddings generados a partir del texto en la columna “*customer_review*”:

- Variable objetivo: “*recommended*”. (Variable balanceada, con 50% de reseñas que recomiendan la aerolínea y 50% que no lo hacen).
- Variables predictoras: todas las columnas.
- División del conjunto de datos: 70% para entrenamiento, 15% para validación y 15% para prueba.

Para manejar la alta dimensionalidad de los embeddings y mejorar la eficiencia del modelo, se implementó un proceso de reducción de dimensionalidad mediante Análisis de Componentes Principales (PCA). Se seleccionaron 10 componentes principales con el objetivo de disminuir la carga de procesamiento. Estos componentes fueron añadidos como nuevas columnas al dataset. Posteriormente, se eliminaron los embeddings originales y la columna “*customer_review*” para optimizar el uso de memoria y simplificar el conjunto de datos

Para entrenar el modelo, se utilizó RandomizedSearchCV en combinación con validación cruzada para optimizar los hiperparámetros. Este enfoque permite realizar una búsqueda eficiente de los mejores valores de los hiperparámetros, probando combinaciones aleatorias dentro de un rango definido. En este modelo, se ajustaron varios hiperparametros, incluyendo subsample, reg_lambda, reg_alpha, n_estimators, max_depth, learning_rate, y colsample_bytree. Los mejores parámetros encontrados fueron:

- subsample: 0,6
- reg_lambda: 10
- reg_alpha: 5
- n_estimators: 100
- max_depth: 3
- learning_rate: 0,1
- colsample_bytree: 0,6

Estos parámetros fueron seleccionados para maximizar la capacidad predictiva del modelo, equilibrando su complejidad y evitando el sobreajuste.

Resultados

En este análisis se compararon dos enfoques principales para predecir si los pasajeros recomendarían una aerolínea o no (Anexo 15). Los modelos evaluados, Regresión Logística y XGBoost Classifier, difieren en su nivel de complejidad y en el uso de información textual. A continuación, se presentan los resultados obtenidos:

Modelo	Accuracy	Precision	Recall	F1 Score	AUC
Regresión Logística	0.9708	0.9753	0.9653	0.9702	0.9707
XGBoost	0.9731	0.9777	0.9676	0.9726	0.9939

Figura 13: Comparación de modelos. Tabla de elaboración propia

Regresión logística

El modelo de Regresión Logística mostró un rendimiento sólido y consistente con valores cercanos al 97% en todas las métricas evaluadas, lo que indica una excelente capacidad para clasificar correctamente a los clientes que recomendarían o no la aerolínea.

La matriz de confusión respalda el desempeño del modelo al mostrar que:

- Verdaderos Positivos: 1223 clientes satisfechos clasificados correctamente como "recomendadores".
- Verdaderos Negativos: 1271 clientes insatisfechos correctamente identificados como "no recomendadores".
- Falsos Positivos: 31 clientes insatisfechos erróneamente clasificados como "recomendadores".
- Falsos Negativos: 44 clientes satisfechos erróneamente clasificados como "no recomendadores".




Figura 14: Matriz de confusión de regresión logística. Imágen de elaboración propia.

El gráfico de la matriz de confusión muestra que la cantidad de falsos positivos y falsos negativos es baja, indicando un rendimiento eficaz. Sin embargo, los falsos negativos pueden ser problemáticos. Ocurren cuando un cliente satisfecho es clasificado erróneamente como insatisfecho. Esto puede llevar a invertir recursos para mejorar una situación que ya es positiva, desviando el enfoque de los problemas reales que afectan a los clientes insatisfechos.

El análisis de overfitting muestra que el modelo tiene una consistencia notable entre los conjuntos de datos:

- Accuracy en el conjunto de entrenamiento: 97,27%
- Accuracy en el conjunto de validación: 97,04%
- Accuracy en el conjunto de prueba: 97,08%

La diferencia mínima en los valores de accuracy entre el conjunto de entrenamiento, validación y prueba sugiere que el modelo tiene una buena capacidad de generalización. No se observa una diferencia significativa entre los resultados, lo que indica que no existe un overfitting. Si el modelo estuviera sobreajustado, esperaríamos un accuracy mucho más alto en el conjunto de entrenamiento en comparación con los conjuntos de validación y prueba.

Regresión XGBoost con embeddings textuales

El modelo de XGBoost Classifier, que incorporó embeddings textuales procesados mediante PCA, presentó un rendimiento mejor, destacándose en métricas avanzadas como el AUC.

La matriz de confusión mostró lo siguiente:

- Verdaderos Positivos: 1226 clientes satisfechos correctamente clasificados como "recomendadores".
- Verdaderos Negativos: 1272 clientes insatisfechos correctamente clasificados como "no recomendadores".
- Falsos Positivos: 28 clientes insatisfechos erróneamente clasificados como "recomendadores".
- Falsos Negativos: 41 clientes satisfechos erróneamente clasificados como "no recomendadores".




Figura 15: Matriz de confusión de XGBoost. Imágen de elaboración propia.

XGBoost tiene un desempeño ligeramente superior en todas las métricas de la matriz de confusión, con menos falsos positivos y falsos negativos, lo que implica una mejor capacidad para clasificar tanto a los recomendadores como a los no recomendadores.

El análisis de overfitting muestra que el modelo presenta una consistencia notable entre los conjuntos de datos:

- Accuracy en el conjunto de entrenamiento: 97,74%
- Accuracy en el conjunto de validación: 97,55%
- Accuracy en el conjunto de prueba: 97,23%

La mínima diferencia entre accuracy entre los conjuntos indica una buena capacidad de generalización, sin signos de overfitting. Si hubiera sobreajuste, esperaríamos un accuracy significativamente mayor en entrenamiento.

Como se evidencian los resultados en la Figura 13 que, aunque ambos modelos presentan un rendimiento excelente, XGBoost supera a Regresión Logística en términos de AUC (0,9939 frente a 0,9707), lo que refleja una mayor capacidad de diferenciación entre clases. Sin embargo, la diferencia en accuracy entre ambos modelos es mínima, lo que sugiere que ambos tienen un desempeño similar en términos de precisión general.

En términos prácticos, el uso de embeddings textuales en XGBoost mejora ligeramente el rendimiento, especialmente en la capacidad de distinguir entre clases. Sin embargo, los factores cuantitativos básicos, representados por las variables estructuradas del dataset, siguen siendo los más determinantes para predecir si un cliente recomendaría el servicio. Las variables que más aportaron al modelo, según el análisis de “Gain”, fueron *"Value_for_Money"*, *"Overall"*, *"Cabin_Service"* y *"Ground_Service"*.




Figura 16: Top 10 Variables más importantes según Gain. Imágen de elaboración propia.

3.5.3 Análisis de sentimientos en Twitter

Para el desarrollo de los modelos y su posterior comparación se realizaron los siguientes pasos:

- Las filas con “*airline_sentiment*” igual a “neutral” fueron eliminadas del conjunto de datos.
- Los valores de “*airline_sentiment*” fueron recodificados: “positive” se reemplazó por 1 y “negative” por 0, transformando la variable objetivo en un formato binario adecuado para modelos de clasificación.

El procesamiento textual fue un componente clave en este modelo. Para capturar el significado semántico de las reseñas, se utilizaron embeddings generados mediante el modelo preentrenado “all-MiniLM-L6-v2”, conocido por su efectividad en tareas de representación de texto en espacios vectoriales. La columna ‘*text*’, que contenía las reseñas de los usuarios previamente limpiadas y normalizadas, se transformó en vectores de características de alta dimensionalidad que representan la esencia del contenido textual. Estos embeddings proporcionan una representación rica y contextualizada de las reseñas, preservando las relaciones semánticas entre

palabras y frases. Esta transformación asegura que el modelo pueda captar patrones complejos en los datos de texto, mejorando así su capacidad predictiva.

Los embeddings y la variable objetivo “*airline_sentiment*” fueron divididos en dos subconjuntos: entrenamiento y prueba. La división permitió entrenar los modelos utilizando una parte de los datos y reservar otra para evaluar su rendimiento de manera objetiva. Este enfoque asegura que el modelo sea capaz de generalizar datos no vistos y minimiza el riesgo de sobreajuste.

Se implementaron y compararon varios algoritmos de clasificación:

- XGBoost: capturan relaciones no lineales y patrones complejos.
 - Hiperpárametros: eval_metric="logloss", random_state=42, max_depth=2, min_child_weight=30, subsample=0,8, colsample_bytree=0,8, n_estimators=50, learning_rate=0,05
 - La reducción en la profundidad de los árboles y el aumento en el peso mínimo de los nodos ayuda a prevenir el sobreajuste y mejora la generalización. El muestreo parcial de datos y de características asegura que el modelo no dependa demasiado de ninguna característica o muestra, lo que lo hace más robusto.
- Random Forest: robusto frente a datos ruidosos y proporciona una buena capacidad de generalización.
 - Hiperpárametros: random_state=42, max_depth=4, min_samples_split=25, min_samples_leaf=15, n_estimators=150, max_features='sqrt', class_weight="balanced"
 - La restricción en la profundidad de los árboles y el aumento en los requisitos de muestras para dividir nodos y hojas evita el sobreajuste y mejora la robustez del modelo. El mayor número de árboles y el muestreo de características optimizan la precisión, mientras que el balanceo de clases mejora el rendimiento en clases desbalanceadas.
- Regresión logística: Modelo simple, pero interpretable y rápido de entrenar.
 - Hiperpárametros: max_iter=1000, random_state=42, C=0.1, solver="lbfgs"
 - Los hiperparametros ajustados mejoran la convergencia y la estabilidad del modelo. Aumentar max_iter=1000 asegura que el modelo tenga suficientes

iteraciones para converger correctamente. La regularización con $C=0.1$ controla el sobreajuste, favoreciendo una solución más generalizable. El uso del solver lbfgs mejora la eficiencia y la precisión en problemas con un número moderado de características, manteniendo el modelo rápido y eficiente.

- Gradient Boosting: al igual que XGBoost, capturan relaciones no lineales y patrones complejos
 - Hiperparámetros: `random_state=42`, `n_estimators=50`, `learning_rate=0.2`, `max_depth=2`, `min_samples_split=10`, `min_samples_leaf=5`
 - Los hiperparámetros optimizan la capacidad del modelo para capturar patrones complejos y mejorar la generalización. La reducción en la profundidad de los árboles y los requisitos más estrictos para dividir nodos y hojas previenen el sobreajuste. La tasa de aprendizaje moderada acelera la convergencia mientras controla el ajuste del modelo, y el menor número de árboles mejora la eficiencia y rapidez del entrenamiento.

La combinación de estos enfoques permitió evaluar cuál modelo se ajustaba mejor a los datos y producía mejores resultados en términos de precisión y capacidad para clasificar correctamente los sentimientos de los usuarios hacia las aerolíneas. Los hiperparámetros fueron cuidadosamente ajustados con el fin de evitar el overfitting y asegurar que los modelos fueran robustos.

Resultados

Se evaluaron cuatro modelos de aprendizaje automático (XGBoost, Random Forest, Logistic Regression y Gradient Boosting) para la clasificación del sentimiento en Twitter (Anexo 6). Los modelos fueron comparados considerando métricas clave como precisión, recall, F1 Score y AUC, además de su capacidad de generalización y balance entre entrenamiento y prueba.

Métricas del entrenamiento:

Modelo	Accuracy	Precision	Recall	F1 Score	AUC
1. XGBoost	0,904	0,8981	0,9917	0,9426	0,9593
2. Random Forest	0,9511	0,9712	0,9672	0,9692	0,9848
3. Regresión Logística	0,9877	0,9873	0,9973	0,9923	0,9984
4. Gradient Boosting	0,9564	0,9548	0,9922	0,9732	0,9908

Métricas del test:

Modelo	Accuracy	Precision	Recall	F1 Score	AUC
1. XGBoost	0,899	0,8944	0,9894	0,9395	0,9514
2. Random Forest	0,9415	0,9408	0,9887	0,9642	0,9735
3. Regresión Logística	0,9832	0,9856	0,9934	0,9895	0,9967
4. Gradient Boosting	0,9435	0,9446	0,9869	0,9653	0,9796

Figura 17: Métricas generales de los modelos. Tablas de elaboración propia

1. XGBoost

El modelo XGBoost mostró un buen desempeño en términos generales. Aunque la precisión fue buena, el recall fue notablemente más alto, lo que indica que el modelo logra identificar la mayoría de los casos positivos. El F1 Score, que combina precisión y recall en una sola métrica, refleja un buen equilibrio entre ambas. y el AUC demuestra una capacidad sólida para diferenciar entre clases.

La matriz de confusión:

- Verdaderos Positivos: 2719 casos positivos clasificados correctamente.
- Verdaderos Negativos: 385 casos negativos clasificados correctamente.
- Falsos Positivos: 321 casos negativos clasificados erróneamente como positivos.
- Falsos Negativos: 29 casos positivos clasificados erróneamente como negativos.




Figura 18: Matriz de Confusión - XGBoost. Imágen de elaboración propia.

El análisis de overfitting muestra que el modelo tiene una consistencia notable entre los conjuntos de datos:

- Accuracy en el conjunto de entrenamiento: 90,04%
- Accuracy en el conjunto de prueba: 89,9%

No se observa una diferencia significativa entre los resultados, lo que indica que no existe un overfitting. Si el modelo estuviera sobreajustado, esperaríamos un accuracy mucho más alto en el conjunto de entrenamiento en comparación con los conjuntos de validación y prueba.

2. *Random Forest*

El modelo Random Forest tuvo un rendimiento superior en comparación con XGBoost, destacándose por su precisión y recall, lo que refleja una mejor capacidad para hacer predicciones correctas, con menos falsos positivos. Su F1 Score resalta el balance entre ambos aspectos, y el AUC demuestra una buena capacidad para distinguir entre clases.

La matriz de confusión:

- Verdaderos Positivos: 2719 casos positivos clasificados correctamente.

- Verdaderos Negativos: 535 casos negativos clasificados correctamente.
- Falsos Positivos: 171 casos negativos clasificados erróneamente como positivos.
- Falsos Negativos: 31 casos positivos clasificados erróneamente como negativos.




Figura 19: Matriz de Confusión - XGBoost. Imágen de elaboración propia.

El análisis de overfitting muestra una mayor distancia entre los conjuntos:

- Accuracy en el conjunto de entrenamiento: 90,04%
- Accuracy en el conjunto de prueba: 89,9%

Se observa una diferencia entre los resultados, lo que indica que existe un mínimo overfitting.

3. Logistic Regression

El modelo de regresión logística destacó como el mejor de los evaluados, mostrando una precisión sobresaliente y una capacidad aún mayor detectar los casos positivos reales, lo que refleja un excelente recall. El F1 Score evidencia un equilibrio casi perfecto entre precisión y recall, mientras que su AUC, cercana al máximo posible, confirmando su capacidad superior para distinguir entre clases.

La matriz de confusión:

- Verdaderos Positivos: 2730 casos positivos clasificados correctamente.
- Verdaderos Negativos: 666 casos negativos clasificados correctamente.
- Falsos Positivos: 40 casos negativos clasificados erróneamente como positivos.
- Falsos Negativos: 18 casos positivos clasificados erróneamente como negativos.

Este desempeño no solo es excelente en términos absolutos, sino que también destaca por su simplicidad y capacidad de generalización, lo que lo hace ideal para problemas donde la interpretabilidad es clave.




Figura 20: Matriz de confusión - Regresión Logística. Imágen de elaboración propia.

El análisis de overfitting muestra que el modelo tiene una consistencia notable entre los conjuntos de datos:

- Accuracy en el conjunto de entrenamiento: 98,77%
- Accuracy en el conjunto de prueba: 98,32%

No se observa una diferencia significativa entre los resultados, lo que indica que no existe un overfitting.

4. Gradient Boosting

El modelo de Gradient Boosting también mostró un desempeño sólido, destacándose por su precisión y el alto recall, lo que le permitió detectar casi todos los casos positivos reales. El F1 Score refleja un equilibrio excelente entre precisión y recall. Su AUC de 98.20% refuerza su capacidad para diferenciar entre clases.

La matriz de confusión:

- Verdaderos Positivos: 2712 casos positivos clasificados correctamente.
- Verdaderos Negativos: 547 casos negativos clasificados correctamente.
- Falsos Positivos: 159 casos negativos clasificados erróneamente como positivos.
- Falsos Negativos: 36 casos positivos clasificados erróneamente como negativos.

Aunque su desempeño es muy bueno, los resultados no logran superar a Logistic Regression en términos de equilibrio y generalización.




Figura 21: Matriz de confusión - Gradient Boosting. Imágen de elaboración propia.

El análisis de overfitting muestra una mayor distancia entre los conjuntos:

- Accuracy en el conjunto de entrenamiento: 95,64%
- Accuracy en el conjunto de prueba: 94,35%

Se observa una diferencia entre los resultados, lo que indica que existe un mayor overfitting.

Con base en los resultados, Logistic Regression es claramente el mejor modelo. Su capacidad para generalizar lo posiciona como la opción ideal para este análisis. Además, su simplicidad lo hace altamente interpretable, un aspecto clave en muchos contextos prácticos. Gradient Boosting es una alternativa sólida, mientras que Random Forest y XGBoost presentan un buen desempeño, pero no logran igualar el nivel de rendimiento y estabilidad de Logistic Regression.




Figura 22: Curva ROC. Imágen de elaboración propia.

3.6 Insights y acciones recomendadas

A partir de los resultados obtenidos, se proponen acciones estratégicas enfocadas en mejorar la experiencia del cliente y optimizar la operación de la aerolínea.

3.6.1 Insights y acciones recomendadas para el análisis de sentimientos y tópicos de Skytrax

- **Hallazgo:** Al analizar las reseñas de los pasajeros, se encontró una correlación del 81% entre las reseñas positivas y la probabilidad de recomendación. Es decir, si una reseña es clasificada como positiva, hay un 81% de probabilidades de que el pasajero también recomiende la aerolínea. Este dato confirma la relación directa entre la satisfacción expresada en la reseña y la probabilidad de que el pasajero recomiende la aerolínea.

Además, el análisis de tópicos mostró que los temas recurrentes en las reseñas de United Airlines son similares a los de su competencia, con quejas centradas en retrasos, cancelaciones y experiencia a bordo. Sin embargo, también se identificó un patrón dentro de los sentimientos positivos y negativos, es decir, para algunos pasajeros la experiencia con el personal fue positiva, mientras que para otros, en la misma aerolínea, fue negativa. Esto sugiere que la percepción del servicio puede depender de aspectos más específicos, como el vuelo en particular o el sector dentro del avión.

- **Acción recomendada:** Se recomienda realizar un fine-tuning del modelo de BERT con un conjunto de datos específico de reseñas de United Airlines. Esto aumentará la precisión en la correlación de las reseñas y la probabilidad de recomendación y permitirá definir de manera más clara los tópicos positivos y negativos en las reseñas. Con un modelo más preciso, se podrán identificar mejor las áreas de satisfacción e insatisfacción, facilitando la toma de decisiones estratégicas.
- **KPI para la acción:** Mejora en la identificación de tópicos clave de satisfacción e insatisfacción. Este KPI mide la capacidad de identificar y priorizar los tópicos recurrentes que afectan la experiencia del cliente. Un aumento en la precisión de la identificación de estos tópicos indica que el modelo está permitiendo tomar decisiones más informadas, pudiendo abordar las áreas que se debe mejorar.
- **Modelo más eficiente:** Para el análisis de sentimientos, BERT se destaca sobre VADER, ya que presenta una mayor correlación entre la polaridad de la reseña y la probabilidad de recomendación. En cuanto al análisis de temas dentro de las reseñas, el modelo LDA

permitió identificar los tópicos más frecuentes en las opiniones de los pasajeros, proporcionando insights clave sobre las áreas de mejora prioritarias.

3.6.2 Insights y acciones recomendadas para el Modelos de Clasificación de Recomendación

- **Hallazgo:** El modelo identificó que las variables con mayor correlación con la probabilidad de recomendación de la aerolínea son:
 - Relación calidad-precio (0,89)
 - Servicio en cabina (0,79)
 - Comodidad de los asientos (0,75)
 - Servicio en tierra (0,69)
 - Comida y bebidas (0,58)
- **Acción recomendada:** Para aumentar la tasa de recomendación y la retención del cliente, se sugiere priorizar mejoras en relación calidad-precio, servicio en cabina y comodidad de los asientos, ya que son las variables con mayor correlación con la recomendación. Una estrategia clave sería invertir en la mejora del servicio a bordo, optimizando la atención del personal y la comodidad de los asientos. Además, ajustar la oferta de comida y bebidas con opciones más variadas y de mejor calidad podría generar un impacto positivo en la percepción del valor por el dinero, diferenciando a la aerolínea de la competencia.
- **KPI para la acción:** Mejorar el puntaje general de la aerolínea en la página de Skytrax. Actualmente es de 3/10, así que al mejorar algunas de las características, se espera un aumento del puntaje.
- **Modelo más eficiente:** El modelo XGBoost fue el más eficiente para predecir la clasificación en la recomendación de la aerolínea, logrando un alto desempeño en accuracy, y un mejor área bajo la curva (AUC) en comparación con otros modelos. Su capacidad para manejar grandes volúmenes de datos y capturar relaciones complejas entre variables lo hace ideal para este tipo de análisis.

3.6.3 Insights y acciones recomendadas para el Análisis de sentimientos en Twitter

- **Hallazgo:** Se detectó un valor alto de AUC y accuracy en la clasificación de sentimientos al utilizar embeddings de los tweets, lo que indica que el modelo tiene una alta capacidad para diferenciar entre opiniones negativas y positivas.
- **Acción recomendada:** Implementar el modelo como una herramienta de monitoreo de opiniones en redes sociales. Esto permitirá analizar los sentimientos de los pasajeros en distintos niveles de granularidad: por mes, semana, día o incluso en vuelos específicos. Por ejemplo, si en un vuelo con un atraso de más de 5 horas la mayoría de los comentarios negativos mencionan la falta de información o el impacto en la rutina de los pasajeros, en futuros vuelos con retrasos se podría anticipar el impacto comunicando la demora con mayor antelación posible.

Aunque el modelo de clasificación solo etiqueta opiniones como positivas o negativas, al analizar patrones en los comentarios a lo largo del tiempo es posible detectar que eventos generan mayor insatisfacción y tomar medidas para mejorar la experiencia del pasajero. Incluso se podría definir un umbral de alerta (por ejemplo: si más del 60% de los tweets sobre un vuelo con retraso son negativos, se debería reforzar la comunicación con los pasajeros en tiempo real).

- **KPI para la acción:** Distribución de sentimientos. Este KPI permitirá evaluar el impacto de las mejoras en la comunicación y resolución de problemas, porque una mayor proporción de comentarios positivos indicaría una respuesta efectiva a los problemas identificados.
- **Modelo más eficiente:** El modelo de clasificación logística, con un accuracy del 98%, fue el más efectivo en la tarea de clasificación, aunque los demás modelos también mostraron un desempeño elevado.

3.7 Futuras Mejoras

Con el objetivo de optimizar aún más el rendimiento de los modelos y aumentar su eficiencia, se proponen varias mejoras para el futuro:

- **Centralización en Vertex IA:** Unificar todos los procesos y el código en Vertex AI no solo optimiza los recursos, sino que también mejora significativamente la velocidad de procesamiento, especialmente en los modelos complejos como BERT. Actualmente, los modelos desarrollados con BERT enfrentan tiempos de procesamiento largos, lo que ralentiza el análisis de grandes volúmenes de datos. Con la centralización en Vertex AI, se podrá aprovechar la infraestructura avanzada y los recursos de cómputo de la plataforma, lo que reducirá considerablemente el tiempo de ejecución.
- **Monitoreo en tiempo real:** Implementar un sistema de monitoreo en tiempo real, utilizando la API de Twitter, permitirá actualizar constantemente el "termómetro" de opiniones sobre las aerolíneas. Aunque los modelos actuales ofrecen buenos resultados, los datos que manejan son de 2015, lo que limita la relevancia de las percepciones actuales. Con el acceso a datos en tiempo real, se podrá observar la percepción más actualizada sobre aerolíneas como United y sus competidores, lo que proporcionará una visión más precisa y actualizada de los sentimientos de los usuarios. Este enfoque permitirá identificar tendencias emergentes y cambios rápidos en la satisfacción o insatisfacción de los clientes, lo que no solo mejorará la calidad del análisis, sino que también facilitará la adaptación de las estrategias de negocio y comunicación, asegurando que las decisiones estén alineadas con las necesidades y expectativas actuales de los usuarios.
- **Ampliación de la fuente de datos con Skytrax:** La base de datos actual limita la capacidad de realizar conclusiones precisas debido a la escasez de información disponible. Por ejemplo, si se cuenta con solo 20 reseñas sobre la ruta de Los Ángeles a Nueva York, es difícil identificar patrones claros y tomar decisiones informadas. Al integrar más datos de Skytrax, se aumentará significativamente el volumen de reseñas y comentarios, lo que permitirá obtener un panorama mucho más amplio y detallado. Con más información, los modelos podrán identificar áreas más específicas de mejora, como problemas recurrentes en ciertas partes del avión o en rutas específicas y permitirá realizar análisis más profundos, proporcionando recomendaciones más específicas para optimizar la experiencia del cliente y enfocar las estrategias de mejora.

Conclusiones Generales

El propósito principal de este trabajo fue desarrollar una prueba de concepto para una solución de datos permitiendo a United Airlines entender y mejorar la experiencia del cliente mediante el análisis de reseñas en la plataforma Skytrax y comentarios no estructurados de Twitter (actualmente X). La propuesta integra técnicas de análisis de sentimientos y modelado de temas, junto con modelos de clasificación, para identificar áreas clave de mejora en los servicios de la aerolínea.

Las opiniones y reseñas analizadas no solo revelan las necesidades y falencias desde la perspectiva de los pasajeros, sino que además influyen en la percepción de la marca y en las decisiones de los posibles clientes. En un sector competitivo como la industria aérea, donde las expectativas de los clientes son altas y las plataformas de reseñas tienen gran influencia, este tipo de análisis es fundamental para alinear la oferta de servicios con lo que demandan los clientes. Además, el análisis detallado de los datos permitió identificar patrones y problemas recurrentes que pueden ser priorizados según el impacto directo en la satisfacción del cliente. Esto incluye problemas como la comodidad en el asiento, puntualidad y atención al cliente.

El desarrollo de este proyecto presentó desafíos importantes pero también permitió obtener aprendizajes. La limpieza y preparación de datos requirió estandarizar variables y extraer información adicional de las reseñas, lo que destacó la importancia de trabajar con datos no estructurados y realizar ajustes para obtener información precisa. Además, el procesamiento de grandes volúmenes de datos demandó optimización y recursos computacionales adecuados, resaltando la necesidad de una infraestructura eficiente para manejar datasets grandes. Finalmente, el análisis de tópicos, pese al uso de técnicas avanzadas como LDA, necesitó ajustes constantes para obtener resultados coherentes y representativos, destacando la importancia de realizar pruebas continuas para asegurar la calidad de los resultados.

Este proyecto destaca el potencial de utilizar fuentes de datos públicas y herramientas avanzadas de análisis para abordar problemas de negocios. Skytrax y Twitter son dos ejemplos de recursos públicos para captar las percepciones de la experiencia de los pasajeros. Implementar soluciones

basadas en estos análisis no solo tendrá un impacto positivo en la experiencia del cliente, sino que también sentará las bases para la toma de decisiones informadas.

A futuro, este análisis podría evolucionar de diversas maneras. La aerolínea podría integrar estos modelos con sistemas CRM (Customer Relationship Management) para personalizar la atención del cliente en función de las emociones detectadas en reseñas y redes sociales. Un paso más allá sería utilizar modelos de predicción en tiempo real, alimentados por datos de redes sociales y plataformas de reseñas para poder anticipar problemas operativos y de esa manera evitarlos, y que no afecten a los clientes. Otra proyección sería complementar el análisis de reseñas y redes sociales con encuestas directas a los pasajeros. Al integrar los datos con encuestas personalizadas sobre la experiencia de vuelo, la aerolínea podría obtener una visión más completa y precisa de los aspectos clave que impactan la satisfacción de los clientes. Además, la combinación de datos de diferentes fuentes ayudaría a verificar la consistencia de las percepciones y a identificar posibles áreas de mejora que no se capturan solo en un canal.

El desarrollo para este proyecto puede ser replicado y adaptado a otros contextos, no solo en la industria aérea, sino que en cualquier industria donde las opciones sean determinantes para el éxito, es decir, para prácticamente cualquier industria.

Referencias

[1] PuroMarketing. (2016, 21 de noviembre). El 84% de los usuarios confía en una opinión online tanto como en la de un amigo.

<https://www.puromarketing.com/88/27994/usuarios-confia-opinion-online-tanto-como-amigo>

[2] Danisman, E. (2020). Skytrax Airline Reviews.

<https://www.kaggle.com/datasets/efehandanisman/skytrax-airline-reviews>

[3] AirlineQuality. (n.d.). *United Airlines reviews*. AirlineRatings. Recuperado el 30 de diciembre 2024.

<https://www.airlinequality.com/airline-reviews/united-airlines>

[4] Datasets. (n.d.). *Airport codes dataset*. GitHub.

<https://github.com/datasets/airport-codes/blob/main/data/airport-codes.csv>

[5] Prudhvi Teja, D (n.d.). Twitter US airline sentiment dataset. Kaggle.

<https://www.kaggle.com/datasets/dprudhviteja/twitter-us-airline>

[6] Russell, S., & Norvig, P. (2003). Artificial intelligence: A modern approach (2nd ed.). Prentice Hall.

https://people.engr.tamu.edu/guni/csce421/files/AI_Russell_Norvig.pdf

[7] Jurafsky, D., & Martin, J. H. (2024). Speech and Language Processing (3rd ed.).

<https://web.stanford.edu/~jurafsky/slp3/ed3book.pdf>

[8] Medhat, W., Hassan, A., & Korashy, H. (2014). Sentiment Analysis Algorithms and Applications: A Survey. Ain Shams Engineering Journal.

<https://doi.org/10.1016/j.asej.2014.04.011>

[9] Blei, D. M., Ng, A. Y., & Jordan, M. I. (2003). Latent Dirichlet Allocation. Journal of Machine Learning Research.

<https://jmlr.org/papers/volume3/blei03a/blei03a.pdf>

[10] Cheddak, S., Ait Baha, T., Es-Saady, Y., El Hajji, M., & Baslam, M. (2024). *BERTopic: Neural topic modeling with a class-based TF-IDF procedure*. arXiv.

<https://arxiv.org/abs/2203.05794>

[11] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. Advances in Neural Information Processing Systems.

https://papers.nips.cc/paper_files/paper/2017/file/3f5ee243547dee91fbd053c1c4a845aa-Paper.pdf

[12] Mikolov, T., Chen, K., Corrado, G., & Dean, J. (2013). Distributed representations of words and phrases and their compositionality. Advances in Neural Information Processing Systems.

<https://arxiv.org/pdf/1310.4546>

[13] Pennington, J., Socher, R., & Manning, C. D. (2014). GloVe: Global Vectors for Word Representation. Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP). <https://aclanthology.org/D14-1162.pdf>

[14] Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks.

<https://aclanthology.org/D19-1410.pdf>

[15] Hugging Face. (n.d.). *RoBERTa: A Robustly Optimized BERT Pretraining Approach*. Hugging Face. https://huggingface.co/docs/transformers/main/en/model_doc/roberta

[16] Galton, F. (1886). Regression towards mediocrity in hereditary stature. Journal of the Anthropological Institute of Great Britain and Ireland. <https://zenodo.org/record/1449548>

- [17] Cramer, J. S. (2002). The origins of logistic regression. Tinbergen Institute Discussion Paper. <https://www.econstor.eu/bitstream/10419/86100/1/02119.pdf>
- [18] Breiman, L. (2001). Random Forests. Machine Learning, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>
- [19] Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 785–794. <https://doi.org/10.1145/2939672.2939785>
- [20] IBM. (2023). Principal component analysis. IBM. <https://www.ibm.com/think/topics/principal-component-analysis>

Anexos

Anexo 1: Data Product Canvas

Data Product Canvas		Product Name:	Owner:	Date:	Version:
Problem  <i>Ask the right questions:</i> - What is the problem? - Why is it a problem? - Whose problem is it? - Why, why and why...? 1	Data  <i>Ask the right questions:</i> - Source - Quality - Access vs. Availability - Process / Transformation - Outputs - Test / Training / Validation 3	Solution  <i>Ask the right questions:</i> - Type (Analytics, ML, IA,) - What will be the solution? - Output expected? 2	KPIs  <i>Ask the right questions:</i> - How to evaluate the model? - Which metrics should be used? - How much uncertainty can we handle with? - AB Test – How? 7	Actions  <i>Ask the right questions:</i> - Which actions will be used? - Which campaigns? 6	
	Hypothesis  <i>Ask the right questions:</i> - What will be tested? - What are the expected responses for each of them? - What should we do from each answer? What strategy should we follow? 4		Actors  <i>Ask the right questions:</i> - Who is your client? - Who are your stakeholders? - Who is your sponsor? - Who will use the solution? - Who will consume the solution? - Who will be impact with? 5		
Values  <i>Ask the right questions:</i> - What is the size of your problem? - What is the baseline? - What is the uplift / savings? 8	Risks  <i>Ask the right questions:</i> - What are the risks? - What these risks might block? 9	Performance / Impact  <i>Ask the right questions:</i> - What is the impact? How to measure it? - Where you can see this improvement / performance? <i>Example:</i> - Increase our customers base; - Keep it them by Reduce Churn; - Savings lost revenue + A/B Test; - Reduce cost of acquisition; 10			

 br.linkedin.com/company/dataproductcanvas


Data Product Canvas

 <https://www.dataproductcanvas.com>
Prof. Leandro Carvalho, PhD
 br.linkedin.com/in/leandroscarvalho

Anexo 2: Ejemplo de tipos de datos de Skytrax

2/10

"We are changing to American Airlines"

P Cooper (United States) 26th November 2024

Trip Verified | We paid \$6,000.00 a piece for first class tickets. We could not board until almost everyone else boarded due to some kind of issue. We understand issues but then we got on the flight and we were offered no service. I was thirsty and went to the cabin asking for a bottled water that was on the table. I was told "sorry that's for the pilots". So I asked, will we be offered anything before take off? The stewardess said, "no, we don't have time, we're figuring out the meals right now". My husband and I have flown United for 35 years. We are changing to American Airlines.

Type Of Traveller	Couple Leisure
Seat Type	First Class
Route	Newark to Los Angeles
Date Flown	November 2024
Seat Comfort	
Cabin Staff Service	
Ground Service	
Value For Money	
Recommended	

Anexo 3: Ejemplo de base de twitter

Daniela Calle

@danielaacallee

Seguir

Estamos en un vuelo de @united y la auxiliar de vuelo fue tan grosera con nosotras. Literal estoy llorando de la rabia. al principio pense como no te dejes quitar la tranquilidad, pero siguio siendo super grosera y despectiva. No se si es porque somos latinas o pareja o que onda.

09:49 · 14/07/2019

1k

1,3k

13,7k

52

Respuestas más relevantes

luzz @bnzalazy · 14/07/2019

Ay recién me despierto y veo esto lpm que rabiaaaa me da esa gente @united háganse cargo de estas cosas por favor

4

Mafe @mafe_hrr · 14/07/2019

Que rabia con esa gente Dios

22

67

Anexo 4: Notebook 1: Transformación de base de datos aeropuertos

Transformación y limpieza de la base de datos de aeropuertos. En BigQuery se llevó a cabo únicamente la transformación de los datos, para posteriormente descargar la nueva base, ya limpia y con la información relevante.

Anexo 5: Notebook_2: Transformación_y_limpieza_de_base_de_datos_Skytrax.ipynb

Transformación y limpieza de la base de datos Skytrax. Se realizó el tratamiento de las variables relevantes para el propósito y se unificó con la base modificada de aeropuertos.

Anexo 6: Notebook 3: Análisis_y_Modelado_Twitter.ipynb

Debido a su simplicidad, todo el proceso se llevó a cabo en la misma notebook. En primer lugar, se realizó la transformación de los datos pertinentes de la base de Twitter, seguida del análisis exploratorio, y finalmente, el desarrollo del modelo.

Anexo 7: Notebook 4 - EDA_reviews.ipynb

En esta notebook se desarrolla el análisis exploratorio de las variables y se demuestra que el balanceo de los datos es correcto. Este proceso corresponde al siguiente paso después de la transformación de los datos realizada en la Notebook 2.

Anexo 8: Notebook 5 - Análisis_de_sentimientos_y_tópicos.ipynb

En esta notebook se desarrolla una de las soluciones propuestas, enfocándose en el análisis de sentimientos y la identificación de tópicos temáticos utilizando la base de datos de Skytrax. Este proceso permite extraer información relevante sobre las opiniones y temas principales relacionados con los datos analizados, proporcionando una visión más profunda y estructurada.

Anexo 9:

Texto completo y original de las reseñas tomadas para el desarrollo de los sentimientos ambiguos.

Comentario completo	Sentimiento con VADER	Sentimiento con BERT
I had booked a trip to Hong Kong through Flight Network. on the way there (14 hour flight) the plane did not have any entertainment units or even a plug in for a laptop. On our way back we were to go from Hong Kong to San Francisco and then from San Francisco to Edmonton. United Airlines had switched the connecting flight to go through Chicago instead of San Francisco which I only found out when checking in on our departure day. The attendant at the United desk was unable to provide an explanation as to why the connection was switched and was basically of no help. This ended up amounting to a 9 hour delay and me missing a day at work.	Neutral	Negative
Orlando to Charlotte. Flew this airline cause it was a shorter flight and it was relatively short compared to other airlines. Then when I got to the counter I had to pay 45 dollars for a carry on. I've flown many times before and have never had to pay for a carry on. If I would have know this I would've packed a bigger back to check instead of cramming everything into a small suitcase	Negative	Neutral
Austin to Durango via Dallas. Well we made our flight to Dallas barely on time. Then our flight was delayed but that was ok we were going to make it, we made it to our gate on time only to find that it was closed and people on standby were put ahead of us, even though we were expected to make our flight and we bought our tickets months in advance. Thank you American legal for the worst flight experience ever. The flight attendants were polite, but they couldn't do anything for us	Neutral	Negative

Anexo 10:

San Francisco to New York. I paid as much money as anybody else, however my seat at the very back of the plane was not reclining on an overnight flight. The little comfort I could have had was not given to me. The stewardess told me there is nothing she can do. <u>I do not recommend the airline.</u>	Neutral	Negative
First and absolute last time we will ever fly with Spirit Airlines. Scheduled to leave Fort Lauderdale, FL only for it to be delayed twice and then cancelled due to "weather" even though the representative on the phone let it slip that it was an "air traffic over-scheduling issue" before he then said "oh, and weather" because of course then it's not their problem. Had to rent a car and drive 2 hours to Fort Worth at midnight to spend triple on a ticket back to Minnesota for the next day. <u>Never book with them. Our first and last time.</u>	Positive	Negative
I bought 2 tickets to fly with my boyfriend. Both to and from our destination our seats were split up. I called customer service and they told me it's gate seating and 99.9% of the time you get to sit together. Clearly not that percentage when it happened both flights. What is the point of buying tickets together when they don't even seat you together. <u>I will never recommend nor fly American again.</u>	Positive	Negative

Anexo 11: Ejemplo representativo reseña negativa tópico 1- United Airlines:

Never flying United Airlines again. I recently took a trip from North Dakota to Brisbane and back. United managed to ruin over 60% of my flights. It started on my 2nd flight on the way

there. The aircraft was delayed for almost 3 hours and did not take off until it should have been landing in San Francisco. Not only that we as customers were given different reasons as to the delays. One said too much rain for 1.5 hours of the delay and the other said too much wind for the other 1.5 hour delay. Landed in San Francisco the ground was barely wet and there was no wind at all. Get off the plane to the overhead pagers telling us that they are going to close the door for the connecting flight to Auckland NZ, mind you 35 passengers were on the plane late from Denver. Plane gets into NZ late miss my connection and have to sit in NZ for 6 hours until the next flight leaves for Brisbane. Return trip stuck in Denver again. Flight crew lied to passengers said it was weather related when in reality they were out of hours. Given 6 hours in a hotel room to sleep and then back to the airport for the flight to be cancelled yet again. Crew blamed weather and that was a lie. The aircraft they were flying was not the proper aircraft to land on the runway in ND as it had no revers thrusts. Same aircraft as the night before so they lied about twice to their customers. Customer Service desk in Denver was not helpful at all. Had to catch a flight out that night to Bismarck which is 3 hours away from home when I should've been flying into Williston 45 mins away. Land in Bismarck and my luggage was sent to Williston and not moved over onto the proper plane. 3 hour drive back from Bismarck and my luggage should've been delivered to my door and yet it was not. Had to make the delivery company deliver it that night like I had informed Williston United personnel that it needed to be. Had to wait almost an extra 2 hours for my luggage to be delivered when it is a 45 minute drive thanks to slow and lazy delivery service. Wrote to Customer Care and they offered me a lousy 300 dollar flight voucher. They offer up to 1k dollar flight vouchers when they over book a plane yet 300 dollars is acceptable to them after wasting 30 plus hours of a paying customers life?? United has 100 percent lost my business and I will make sure I inform everyone I know to choose other Airlines. I am writing this so that if anyone considering flying United Reads this to be aware and to stay away from them as they will Lie to you without issues and they will do absolutely nothing to make things right when they provide horrible service and cause you to be late getting to and from your destinations. They simply do not care as a Corporation about their Customer base.

Anexo 12: Ejemplo representativo reseña negativa tópico 2 - United Airlines:

First time flying this route from Houston to Honolulu and I was not looking forward to it. Why? 8 hours in the sky with no free hot meals (you have to purchase from a menu and it's not cheap - \$10 for a burger), no in-flight entertainment screens, and a sardine can economy cabin with the 3-4-3 seating arrangement. All this in mind and I was not eager to fly. As I boarded the plane and settled in my seat I noticed that yes the seats got narrower to accommodate more seats across but the seats are also new and well crafted with details. The seat was made out of this leather with detailed stitching patterns and a tag on the side that had the United logo on it and it had a cool color scheme to it too. Not only did it look good but it felt fairly comfortable for a small seat and the cushioning was decent. Legroom was also tolerable and take my word for it because I have very long legs. The seats didn't have those necessary in-flight entertainment screens but all seats were installed with a tablet/device holder so you can comfortably watch free entertainment on your personal device via the United wifi. (Make sure you have downloaded the United app before you board). The wifi connectivity was fairly strong though it didn't work the last half of the flight. Cabin crew were pleasant. They had poise, well groomed and very polite and I have no complaints or problems with them. The only huge disappointment I have is that for an 8-hour flight, no free meals were offered! It felt like a long-haul budget carrier flight! Of course, there was a full drink service. If you wanted to eat, you had to order from the menu a wide selection of hot meals that costed upwards \$10. If it was that expensive then it should taste good I thought - which did. \$10 Mediterranean chicken wrap was a rather small portion for a \$10 meal but the tastes were worthy enough for you to think it came from Chipotle or something.

Anexo 13: Ejemplo representativo reseña positiva tópico 1 - United Airlines:

Houston to New York. Thank you to the kindness of United Airlines employees. On February 13 at 2pm the woman (who saw on the VIP line), helped me with respect and kindness and the whole staff at United was great. I was on my 3 month MD Anderson Cancer Center treatment trip. I always fly in on a Tues and leave the next day (Wed) for medical treatments. There is a lot of stress involved with this quarterly trip and I will not go into that. In any event, I was in my Uber on my way back from MD Anderson to the airport and I had to call United because I was having an error checking in online. I actually was taking the trip to NYC instead of Rochester because the flights were too high and because of my medical situation, I am limited financially and need to be very frugal about my trips for my treatments. So I decided it would be cheaper to

fly into NYC, visit the night with a friend and take the train the next day! In my call to United from my Uber, we realized that I had booked the trip back home on March 13th instead of Feb 13th. I had never noticed the error. The United employee on the phone said she could book me for a later flight that day but it would be \$700 additional dollars on top of my flight. (I purchased the flight insurance because of fear of problems but since the error was on my end, I'm sure I wouldn't have been helped by the insurance.) In any event, I told her I would just talk to someone when I got the airport but she did say they wouldn't do any better!. I was beyond stressed as with the whole medical situation and having to travel alone and the cost the quarterly trips take with hotels and travel etc. I went to talk to the United employee who was at the Airport and when I started to explain what happened, I just lost it. I went to pieces. And I am the type of person who never cries in front of anyone, let alone in a public place. I couldn't even explain what happened I was too upset. In any event, I was treated professional and so kindly at the United desk. This woman and her manager (not sure who was either) really helped me. They worked something out for me and I was able to take the same flight that I thought I was booked on and it just so happened it was somewhat delayed so the timing was perfect. I can't express how much that helped me that day and how much I appreciate how I was treated!!! Thank you United Airlines! If cost permits, I will stay loyal to your airline because of how decently I was treated.

Anexo 14: Ejemplo representativo reseña positiva tópico 2 - United Airlines:

Lisbon to Newark. The new Polaris Business class of United is a very nice product. The seats are comfortable, the screen is a nice size and the new amenities kit is excellent. The seats are lie flat and offer a great rest. However, they are somewhat difficult to adjust at the intermediate levels, the upright and lie flat are done at the push of a button. Other than that, the only complaint I had was for the lack of storage on the seat - the old seats (and this may have been the ones in first) and small nooks to store stuff. That is not the case here, or at least I did not find them - so the storage has to be done in the overhead bins. Besides the very comfortable oversized pillow, United also provides you with two blankets, a regular one, and a slightly heavier quilted one. I initially used the quilted one, but since the temperature in the cabin was quite comfortable I eventually gave up on both. The food is a little lacking, for the first course, I chose the Halibut which was very good but second meal was a very dry and flavorless piece of chicken breast. This, in my opinion, is a problem, primarily because it is served an hour before landing and

sticks in people's memories as their meal experience. The service while professional is not on par with European, Asian or Middle Eastern carriers. While I cannot put my finger on it simply lacks the elegance and savoir-faire of their counterparts. Another big issue is the entertainment, while there is an excellent selection I cannot for the life of me understand why I constantly have to be subjected to Barracuda and Marriott advertising - it is not just once, but after every single show that I want to watch. This really cheapens the United brand, if you want to do it on the domestic legs to offset the entertainment costs the so be it - but to do it on the international leg in business class is unheard of. United is definitely on to something with Polaris, with a little fine tuning this could become a Business Class for others to follow.

Anexo 15: Notebook 6 - Modelos_de_Clasificación_Si_Recomienda_Aerolinea.ipynb

En esta notebook se desarrollan modelos de clasificación para determinar si se recomienda o no, tomando como base los datos de Skytrax. Este enfoque representa otra de las soluciones propuestas, centrada en evaluar la satisfacción y las opiniones de los usuarios.

Anexo 16: Repositorio Github <https://github.com/MagdalenaMinoletti/TFG-LIAN?search=1>